CENTRO UNIVERSITÁRIO MATER DEI - UNIMATER

CURSO DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

EDUARDO KRAUSE (RA: 12520157)

PLATAFORMA PARA GERAÇÃO DE CENÁRIOS DE TESTE EM SISTEMAS ERP ASSISTIDA POR MODELOS DE LINGUAGEM, COM VALORES ESPERADOS VERIFICADOS EM BANCO DE DADOS

Proposta de projeto apresentada ao Curso de Tecnologia em Análise e Desenvolvimento de Sistemas do Centro Universitário Mater Dei - UNIMATER, para elaboração do Trabalho de Conclusão de Curso.

Orientador: Prof. Me. João Mazzochin

PATO BRANCO – PR

2026

1. TEMA

Aplicação de modelos de linguagem de grande porte na automação de atividades de garantia de qualidade de software em sistemas de gestão empresarial (ERP), com foco na geração de cenários de teste a partir do requisito e da documentação das rotinas e na determinação de valores esperados a partir de dados reais.

1.1. TÍTULO

Plataforma para geração de cenários de teste em sistemas ERP assistida por modelos de linguagem, com valores esperados verificados em banco de dados.

2. INTRODUÇÃO

A atividade de teste é determinante para a confiabilidade dos sistemas entregues e permanece, em grande medida, dependente de trabalho manual (WANG et al., 2024). Entre as abordagens de especificação, o desenvolvimento guiado por comportamento, ou *behavior-driven development*, descreve o comportamento esperado em linguagem próxima à do negócio, comumente na notação *Gherkin* (SOLIS; WANG, 2011; WYNNE; HELLESOY, 2012). Revisões sistemáticas apontam como principal dificuldade dessa abordagem o esforço de elaboração e manutenção dos cenários (FAROOQ et al., 2023; ARREDONDO-REYES et al., 2023).

Modelos de linguagem passaram a ser aplicados à geração de casos de teste a partir de requisitos em linguagem natural (WANG et al., 2024), com resultados promissores, porém com variabilidade relevante entre as saídas (KARPURAPU et al., 2024; FERNANDES et al., 2025) e risco de produção de conteúdo plausível porém incorreto (SALLOU; DURIEUX; PANICHELLA, 2024). Trabalhos recentes avançam nessa direção ao empregar agentes autônomos na formulação de testes de aceitação em BDD (PADURARU; ZAVELCA; STEFANESCU, 2025), sem que a apuração dos valores esperados seja contemplada. Riscos semelhantes afetam a tradução de linguagem natural para consultas SQL em bases corporativas reais, nas quais o desempenho dos modelos permanece substancialmente inferior ao obtido sobre esquemas reduzidos (LI et al., 2023).

Essas limitações são relevantes em sistemas de gestão empresarial, nos quais executar o teste de um relatório exige conhecer previamente a massa de dados e o valor que o sistema deve apresentar. Soma-se a dificuldade de assegurar

a completude dos cenários, pois o requisito descreve a alteração solicitada, mas não os comportamentos que a rotina já deveria apresentar.

Diante desse cenário, o problema que orienta a presente pesquisa consiste em determinar de que forma os valores esperados de um teste podem ser obtidos de maneira verificável, e não inferida, a partir dos dados efetivamente armazenados no sistema.

3. JUSTIFICATIVA

A elaboração manual de casos de teste consome parcela relevante do tempo do analista de qualidade, que poderia ser direcionado à execução dos testes e à análise de resultados. Em tarefas de relatório e consulta o problema se agrava: antes de executar, o analista precisa localizar a massa de dados adequada e apurar manualmente o valor que o sistema deveria apresentar, atividade que exige acesso ao banco e conhecimento do modelo relacional, e que constitui o ponto de maior consumo de tempo e de maior probabilidade de erro no processo atual.

Um valor esperado incorreto compromete o teste em ambas as direções: pode indicar defeito onde não existe, gerando retrabalho, ou validar como correto um comportamento defeituoso. Em sistemas que envolvem apuração fiscal e contábil, o custo de um defeito não detectado é elevado.

Levantamento realizado junto à equipe de qualidade indica que o emprego de modelos de linguagem já integra a prática corrente, porém por meio de ferramentas de propósito geral, sem aplicação específica à geração de casos de teste ou à apuração de dados em relatórios, e sem integração aos sistemas onde residem o requisito e a documentação. Nesse arranjo, parcela relevante do ganho obtido na redação dos cenários é consumida na tarefa de descrever ao modelo o contexto da rotina, transportado manualmente a cada interação. Ferramentas que não executam consultas tampouco resolvem o problema do valor esperado, pois o apresentam apenas plausível, não verificado. A proposta difere nesses dois pontos: o contexto é obtido por integração direta e o valor de referência provém da execução no banco de dados, cabendo ao consenso entre modelos atuar sobre a etapa de tradução do requisito em consulta.

Do ponto de vista acadêmico, o trabalho situa-se na confluência de duas linhas de pesquisa que vêm sendo tratadas de forma independente na literatura: a geração de casos de teste por modelos de linguagem e a tradução de linguagem

natural para consultas SQL. A contribuição pretendida está em articulá-las, submetendo a saída do modelo à verificação contra os dados efetivamente armazenados, em vez de aceitá-la como plausível, e em avaliar empiricamente essa articulação em um sistema em uso.

No plano social e organizacional, a redução do esforço dedicado à preparação dos testes permite direcionar o tempo do analista à investigação de defeitos, atividade de maior valor e menos suscetível à automação. Do ponto de vista pessoal, o tema decorre da atuação do autor como analista de qualidade no sistema estudado, condição que proporciona acesso ao domínio, à base de dados e ao acervo de tarefas, e que permite avaliar a solução em ambiente real e não em cenário construído para esse fim.

Acrescente-se que a equipe opera em regime de entregas semanais, com volume de tarefas bastante variável. Essa variação desaconselha o uso de tempo médio por tarefa como indicador e reforça o interesse por mecanismos que reduzam o tempo de preparação do teste, cujo efeito é tanto maior quanto mais concentrado o volume de entregas.

4. OBJETIVOS

Esta seção apresenta o objetivo geral do trabalho e os objetivos específicos que o operacionalizam, os quais serão verificados nas bancas de validação do TCC I e de defesa do TCC II.

4.1. OBJETIVO GERAL

Desenvolver uma plataforma que gere cenários de teste a partir de requisitos e documentação de rotinas e apure os valores esperados por consulta ao banco de dados, com validação por consenso entre modelos.

4.2. OBJETIVOS ESPECÍFICOS

- Caracterizar o processo atual de elaboração de casos de teste adotado pela equipe de qualidade.
- Implementar a geração de cenários de teste em notação Gherkin a partir do requisito da tarefa e da documentação funcional da rotina correspondente.
- Implementar a apuração de valores esperados mediante geração de consultas por múltiplos modelos de linguagem, execução no banco de dados e decisão por consenso entre os resultados obtidos.

- Avaliar a qualidade dos cenários gerados e a acurácia dos valores apurados frente a um conjunto de referência, medindo ainda a concordância entre os modelos e o custo de execução.

Cumpre distinguir o alcance do artefato do alcance de sua avaliação. A plataforma opera sobre qualquer área funcional do sistema, uma vez que recebe como entrada o requisito, a documentação da rotina e o esquema do banco de dados, não incorporando conhecimento específico de domínio em sua implementação.

A avaliação, por sua vez, será conduzida nas áreas de estoque e de vendas, escolhidas pela disponibilidade de tarefas históricas acompanhadas de casos de teste elaborados por analistas e de documentação funcional revisada. Registra-se que ambas as áreas compartilham parte do modelo de dados, o que reduz o esforço de mapeamento do esquema, mas também limita a variedade de domínios contemplada na avaliação.

5. METODOLOGIA

O trabalho classifica-se como pesquisa aplicada, de natureza exploratória e abordagem quali-quantitativa, uma vez que produz um artefato de software destinado a resolver um problema prático e avalia seu desempenho tanto por julgamento de especialistas quanto por métricas objetivas.

Adota-se como método a *Design Science Research*, apropriada a trabalhos cujo resultado é a construção e a avaliação de um artefato (HEVNER et al., 2004). O ciclo previsto compreende as etapas de identificação do problema, definição dos objetivos do artefato, projeto e desenvolvimento, demonstração, avaliação e comunicação dos resultados.

5.1. COLETA DE DADOS

A caracterização do processo atual de elaboração de casos de teste foi realizada por meio de levantamento junto aos analistas de qualidade da equipe, complementado pela observação do procedimento adotado nas entregas semanais. Seus resultados encontram-se descritos na justificativa deste trabalho.

Os demais dados serão obtidos pelo próprio autor, na condição de integrante da equipe de qualidade, mediante autorização formal da empresa, a partir de três fontes internas: a ferramenta de gestão de tarefas, a base de documentação funcional e o ambiente de homologação. A validação dos casos utilizados como

referência contará com os demais analistas de qualidade da equipe. A coleta contempla dois conjuntos de dados distintos.

O primeiro é composto por tarefas históricas das áreas de estoque e de vendas, registradas na ferramenta de gestão, contendo a descrição do requisito e o caso de teste elaborado por analista. Esse conjunto atua como referência para avaliação do módulo de geração de cenários. Serão definidos critérios explícitos de inclusão. Registra-se que parcela desses casos foi elaborada com apoio de ferramentas de propósito geral baseadas em modelos de linguagem, prática já incorporada ao trabalho da equipe; esse conjunto representa, portanto, o procedimento atualmente adotado, e é contra ele que o artefato será comparado.

O acervo disponível supera quinhentas tarefas nas áreas consideradas. Dele serão selecionadas aproximadamente trinta tarefas para avaliação do módulo de geração de cenários, quantidade estabelecida para que os indicadores apurados não sejam sensíveis a casos isolados e, simultaneamente, para que o volume de avaliação submetido a cada analista permaneça exequível. Serão informados tanto o total disponível quanto o total efetivamente selecionado, bem como os critérios de inclusão aplicados, de modo a evidenciar que a escolha não recaiu apenas sobre casos favoráveis.

Utiliza-se ainda a base de documentação funcional das rotinas, da qual se extrai o conjunto de comportamentos esperados de cada rotina. Esse material atua como referência de completude na avaliação dos cenários gerados.

O segundo conjunto é formado por perguntas de negócio acompanhadas da consulta SQL correspondente, validada por analista, restritas ao recorte funcional definido. Esse conjunto atua como referência para avaliação do módulo de validação de massa de dados. Considerando que o número de relatórios e consultas existentes nas áreas de estoque e vendas é reduzido, a avaliação contemplará sua totalidade, dispensando procedimento de amostragem e afastando, por consequência, questionamentos quanto à representatividade da seleção.

As execuções ocorrerão em ambiente de homologação, por meio de usuário com permissão exclusiva de leitura, com limite de tempo e de linhas em todas as consultas. Será verificada a origem da base utilizada e, havendo dados pessoais, serão observadas as exigências da Lei Geral de Proteção de Dados. A autorização formal da empresa para uso da base e das tarefas será anexada ao apêndice.

5.2. Descrição do Projeto

Esta seção detalha a forma de execução prevista para cada um dos objetivos específicos enunciados. A plataforma é composta por dois módulos complementares. A integração direta com a ferramenta de gestão de tarefas e com a base de documentação constitui característica transversal a ambos, por dispensar o transporte manual de contexto que caracteriza o uso de ferramentas de propósito geral.

O primeiro módulo recebe o identificador da tarefa e reúne duas fontes: a descrição do requisito, que informa a alteração solicitada, e a documentação funcional da rotina, que informa os comportamentos que precisam permanecer íntegros após a alteração. A partir delas, produz os cenários em notação *Gherkin*, contemplando tanto a verificação da alteração quanto a dos comportamentos já documentados, e devolve o resultado ao analista.

O segundo módulo é acionado quando o requisito envolve relatório ou consulta, e opera segundo as seguintes etapas:

- Classificação do requisito, determinando se há necessidade de apuração de valores no banco de dados.
- Extração do esquema a partir do catálogo do banco, compreendendo tabelas, colunas, tipos, chaves primárias e relacionamentos, seguida da seleção do subconjunto pertinente ao requisito, por similaridade entre seus termos e a nomenclatura das tabelas e expansão pelos relacionamentos existentes.
- Composição de amostra dos dados existentes, com os valores distintos das colunas de baixa cardinalidade e os limites das colunas de data, de modo que a consulta gerada recaia sobre faixas efetivamente povoadas.
- Geração independente da consulta SQL por múltiplos modelos, de origens distintas, a partir do mesmo requisito e do mesmo subconjunto de esquema.
- Verificação em camadas sucessivas: análise sintática que admite exclusivamente comandos de seleção, verificação do plano de execução e execução em conexão somente leitura com limite de tempo e de linhas; candidatos com erro ou retorno vazio são descartados, devolvendo-se a mensagem de erro ao modelo para uma tentativa de correção.

- Normalização dos conjuntos de resultado, com regras explícitas de ordenação, arredondamento, tratamento de valores nulos e formatação de datas, seguida da decisão por consenso, que adota como referência o resultado obtido por ao menos dois dos três modelos e assinala como divergente o caso em que nenhum resultado se repete.
- Composição da saída final, na qual o cenário é entregue com os valores esperados preenchidos e a consulta utilizada anexada para fins de auditoria.

A validação humana é obrigatória em todos os casos, e não apenas nos de divergência. A plataforma não substitui o analista: entrega o cenário elaborado e o valor já apurado, cabendo a ele conferi-los antes da execução. O consenso não constitui aprovação automática, mas indicador do grau de confiança associado ao valor, e a conferência é viabilizada pelo fato de a consulta acompanhar o cenário, permitindo verificar a origem do valor sem reconstruí-lo manualmente.

A decisão por concordância entre gerações independentes apoia-se em resultados que demonstram ganho de acurácia ao substituir uma única saída pela mais frequente entre várias amostragens (WANG et al., 2023). Naquele trabalho, contudo, as amostragens provêm de um mesmo modelo, ao passo que a presente proposta recorre a modelos de origens distintas, com o propósito de reduzir erros correlacionados.

As restrições de domínio recorrentes, tais como delimitação por empresa e filial, exclusão de registros cancelados e tratamento de exclusão lógica, são informadas ao modelo como condições obrigatórias, por constituírem origem frequente de consultas válidas do ponto de vista sintático porém incorretas quanto ao resultado. Registra-se que o banco possui restrições de integridade referencial declaradas, o que permite obter o grafo de relacionamentos diretamente do catálogo.

Não integram o escopo deste trabalho a execução automatizada dos testes, a integração com ferramentas de automação de interface, a geração de massa de dados sintética e qualquer operação de escrita no banco. Registra-se como extensão futura a incorporação das alterações de código vinculadas à tarefa, obtidas do repositório de versionamento, que permitiria identificar rotinas adjacentes afetadas pela alteração, o que não é possível a partir do requisito e da documentação isoladamente.

5.3. Viabilidade

A viabilidade do trabalho sustenta-se na disponibilidade de ambiente de homologação para execução das consultas, na existência de acervo histórico de tarefas com casos de teste elaborados por analistas e na experiência prévia do autor com o domínio de aplicação. Os principais riscos identificados e seus respectivos tratamentos são apresentados a seguir.

Quadro 1 – Riscos identificados e tratamentos previstos

Risco	**Tratamento previsto**
Acesso restrito à base de dados e presença de dados pessoais	Ambiente de homologação com usuário somente leitura, verificação da origem da base, autorização formal da empresa e observância da LGPD.
Escopo superior ao prazo disponível	Delimitação declarada das áreas contempladas na avaliação, sem redução das etapas do processo proposto.
Conjunto de referência elaborado com apoio de ferramentas de propósito geral	Caracterização explícita do conjunto como representativo do procedimento atual da equipe, e não como referência isenta de assistência automatizada.
Documentação funcional desatualizada ou incompleta	Restrição do recorte a rotinas com documentação revisada e registro explícito das lacunas identificadas.
Erro correlacionado entre os modelos	Uso de modelos de origens distintas e medição da taxa de falso acordo.
Junções indevidas e custo de execução com múltiplos modelos	Recuperação seletiva do subconjunto de tabelas, apoiada nas restrições de integridade declaradas, e limitação do número de modelos por execução.

Fonte: elaborado pelo autor (2026).

5.4. Recursos Tecnológicos

Os recursos tecnológicos são descritos a partir da função que desempenham na solução.

Modelos de linguagem são responsáveis pela interpretação do requisito, pela redação dos cenários e pela tradução do requisito em consulta SQL. Serão empregados três modelos de famílias distintas: Claude, desenvolvido pela Anthropic; Gemini, desenvolvido pelo Google; e um modelo de pesos abertos da família Llama, acessado por meio da infraestrutura de inferência da Groq, que não desenvolve modelos próprios. A independência entre as origens é condição para a validade do consenso, e a escolha por três decorre da necessidade de critério de desempate: com dois, a divergência apenas sinaliza discordância, sem permitir decisão. Registra-se que os modelos não são necessariamente equivalentes em porte; a exigência do arranjo é a independência, não a paridade.

O sistema gerenciador de banco de dados adotado é o MySQL, que atua como fonte de verdade da solução, sendo dele que provêm os valores usados como

referência. A extração do esquema é feita pelas visões do catálogo do próprio gerenciador. O modelo de dados é composto por aproximadamente 125 tabelas; ainda que esse volume possa ser submetido integralmente ao modelo de linguagem, adota-se a seleção do subconjunto pertinente, uma vez que a apresentação de tabelas alheias à pergunta tende a induzir junções indevidas e eleva o custo de cada execução sem contrapartida em qualidade.

A integração com a ferramenta de gestão de tarefas e com a base de documentação permite a leitura dos requisitos e o registro dos cenários gerados. A base de documentação constitui, ainda, a fonte do comportamento esperado das rotinas, utilizada tanto na geração dos cenários quanto na avaliação de sua completude.

A camada de orquestração aciona os modelos, executa as consultas de forma controlada, normaliza os resultados e aplica a política de consenso. A execução das consultas é automática, em conexão somente leitura e com limites de tempo e de linhas, por se tratar de operação sem efeito sobre os dados, permanecendo a validação do resultado a cargo do analista. A camada será implementada em Java, com *Spring Boot*, e a interface em *React*, ambas empacotadas em um único artefato executável e executadas localmente, em ambiente interno: as credenciais de acesso aos modelos e ao banco não podem residir no navegador, e o banco corporativo não deve ser exposto à rede externa. Trata-se de escolha de projeto, não de limitação de infraestrutura.

6. Resultados Esperados

Espera-se que a plataforma reduza o tempo necessário à elaboração de casos de teste e, sobretudo, que forneça valores de referência verificados para tarefas que envolvam relatórios e consultas, atualmente apurados de forma manual.

Para o módulo de geração de cenários, serão apuradas as seguintes métricas:

- Proporção de roteiros aceitos sem alteração, aceitos com alteração menor e rejeitados, segundo avaliação de analistas.
- Cobertura em relação ao conjunto de referência, considerando tanto os itens corretamente identificados quanto os adicionais propostos.
- Completude dos cenários gerados em relação aos comportamentos descritos na documentação funcional da rotina.

- Comparação pareada do tempo de elaboração entre o procedimento atualmente adotado pela equipe, apoiado em ferramentas de propósito geral com fornecimento manual de contexto, e o procedimento assistido pela plataforma, aplicando-se ambos sobre o mesmo conjunto de tarefas.

Para o módulo de validação de massa de dados, serão apuradas:

- Taxa de concordância entre os modelos e acurácia do resultado consensuado frente ao conjunto de referência.
- Taxa de falso acordo, correspondente aos casos em que os modelos concordam entre si e divergem da referência, e proporção de casos assinalados como divergentes.
- Proporção de valores esperados alterados pelo analista durante a conferência, indicador direto da confiabilidade da apuração automatizada.
- Custo e tempo médios por consulta.

A avaliação será conduzida por quatro analistas de qualidade da equipe, excluído o autor, cuja participação se restringe à condução do estudo, o que reduz o viés de autoavaliação. Registra-se, como limitação, que a qualidade dos cenários depende da qualidade do requisito e da documentação fornecidos: entradas incompletas tendem a resultar em cenários igualmente incompletos, circunstância que será observada e documentada durante a avaliação.

7. CRONOGRAMA

O cronograma observa o calendário do curso, que distribui o trabalho entre as disciplinas de TCC I, no segundo semestre de 2026, e TCC II, no primeiro semestre de 2027, e está alinhado às entregas parciais acordadas com o orientador.

Quadro 2 – Cronograma de execução do trabalho

Atividade	2026 — TCC I					2027 — TCC II					
	Ago	Set	Out	Nov	Dez	Fev	Mar	Abr	Mai	Jun	Jul
Entrega e defesa da proposta de trabalho	X										
Ajuste da proposta após devolutiva		X									
Mapeamento bibliográfico	X	X									
Fundamentação teórica e trabalhos relacionados	X	X	X								
Arquitetura, modelagem e definição do escopo		X	X								
Plano de validação e definição das métricas		X	X								

Desenvolvimento — geração de cenários		X	X								
Desenvolvimento — apuração por consenso			X	X							
Execução dos experimentos e coleta de dados			X	X							
Consolidação dos resultados e artigo parcial				X							
Validação e defesa do TCC I				X	X						
Ajustes apontados pela banca						X					
Redação do artigo científico						X	X	X	X		
Discussão e considerações finais								X	X		
Revisão final e entrega da versão definitiva									X	X	
Defesa pública do artigo (TCC II)										X	X

Fonte: elaborado pelo autor (2026).

8. Referências

ARREDONDO-REYES, V. M.; DOMÍNGUEZ-ISIDRO, S.; SÁNCHEZ-GARCÍA, Á. J.; OCHARÁN-HERNÁNDEZ, J. O. **Benefits and Challenges of the Behavior-Driven Development: A Systematic Literature Review**. In: INTERNATIONAL CONFERENCE IN SOFTWARE ENGINEERING RESEARCH AND INNOVATION (CONISOFT), 11., 2023. Anais [...]. IEEE, 2023. p. 45-54. DOI: 10.1109/CONISOFT58849.2023.00016.

FAROOQ, M. S.; OMER, U.; RAMZAN, A.; RASHEED, M. A.; ATAL, Z. **Behavior Driven Development: A Systematic Literature Review**. IEEE Access, v. 11, p. 88008-88024, 2023. DOI: 10.1109/ACCESS.2023.3302356.

FERNANDES, H.; PERKUSICH, M.; ALBUQUERQUE, D.; SILVA, I.; SANTOS, D. F. S.; GORGÔNIO, K.; PERKUSICH, A. **A Comparative Study of LLMs for Gherkin Generation**. In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 39., 2025, Recife. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 171-181. DOI: 10.5753/sbes.2025.9888.

HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. **Design Science in Information Systems Research**. MIS Quarterly, v. 28, n. 1, p. 75-105, 2004. DOI: 10.2307/25148625.

KARPURAPU, S.; MYNENI, S.; NETTUR, U.; GAJJA, L. S.; BURKE, D.; STIEHM, T.; PAYNE, J. **Comprehensive Evaluation and Insights Into the Use of Large Language Models in the Automation of Behavior-Driven Development**

Acceptance Test Formulation. IEEE Access, v. 12, p. 58715-58730, 2024. DOI: 10.1109/ACCESS.2024.3391815.

LI, J.; HUI, B.; QU, G.; YANG, J.; LI, B.; LI, B.; WANG, B.; QIN, B.; GENG, R.; HUO, N.; ZHOU, X.; MA, C.; LI, G.; CHANG, K.; HUANG, F.; CHENG, R.; LI, Y. **Can LLM Already Serve as a Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 36., 2023. Datasets and Benchmarks Track. 2023.

PADURARU, C.; ZAVELCA, M.; STEFANESCU, A. **Agentic AI for Behavior-Driven Development Testing Using Large Language Models**. In: INTERNATIONAL CONFERENCE ON AGENTS AND ARTIFICIAL INTELLIGENCE (ICAART), 17., 2025, Roma. Anais [...]. SciTePress, 2025. v. 2, p. 805-815. DOI: 10.5220/0013374400003890.

SALLOU, J.; DURIEUX, T.; PANICHELLA, A. **Breaking the Silence: the Threats of Using LLMs in Software Engineering**. In: INTERNATIONAL CONFERENCE ON SOFTWARE ENGINEERING: NEW IDEAS AND EMERGING RESULTS (ICSE-NIER), 2024. Anais [...]. ACM, 2024. p. 102-106. DOI: 10.1145/3639476.3639764.

SOLIS, C.; WANG, X. **A Study of the Characteristics of Behaviour Driven Development**. In: EUROMICRO CONFERENCE ON SOFTWARE ENGINEERING AND ADVANCED APPLICATIONS, 37., 2011. Anais [...]. IEEE, 2011. p. 383-387. DOI: 10.1109/SEAA.2011.76.

WANG, J.; HUANG, Y.; CHEN, C.; LIU, Z.; WANG, S.; WANG, Q. **Software Testing With Large Language Models: Survey, Landscape, and Vision**. IEEE Transactions on Software Engineering, v. 50, n. 4, p. 911-936, 2024. DOI: 10.1109/TSE.2024.3368208.

WANG, X.; WEI, J.; SCHUURMANS, D.; LE, Q. V.; CHI, E. H.; NARANG, S.; CHOWDHERY, A.; ZHOU, D. **Self-Consistency Improves Chain of Thought Reasoning in Language Models**. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 11., 2023, Kigali. Anais [...]. OpenReview.net, 2023.

WYNNE, M.; HELLESOY, A. **The Cucumber Book: Behaviour-Driven Development for Testers and Developers**. Raleigh: Pragmatic Bookshelf, 2012.

9. APÊNDICE

Serão anexados a este trabalho os seguintes apêndices:

- Apêndice A — Autorização formal da empresa para utilização da base de dados e do acervo de tarefas.
- Apêndice B — Amostra anonimizada do conjunto de tarefas utilizado como referência.
- Apêndice C — Exemplo completo de saída da plataforma, contendo o requisito de origem, o cenário gerado, a consulta utilizada e os valores esperados apurados.