E2 — FICHAMENTO DOS CINCO TRABALHOS MAIS PRÓXIMOS

Eduardo Krause (RA 12520157) — Tecnologia em Análise e Desenvolvimento de Sistemas — UNIMATER

Orientador: Prof. Me. João Mazzochin — Entrega de 08/09/2026

Este documento acompanha a planilha de 40 referências e o arquivo .bib da E2. Reúne o fichamento dos cinco trabalhos mais próximos do problema de pesquisa, cada um respondendo a quatro perguntas: que problema resolve, como resolve, como validou e o que ficou faltando.

O trabalho em curso propõe uma plataforma que gera cenários de teste em notação Gherkin a partir do requisito da tarefa e da documentação funcional da rotina, e que apura os valores esperados por consulta ao banco de dados, com decisão por consenso entre modelos de origens distintas. Os cinco trabalhos abaixo foram escolhidos por tocarem diretamente uma dessas duas metades.

1 AToMIC — geração de testes de aceitação a partir de tarefas do Jira

FONSECA, Pedro Luís; LIMA, Bruno; FARIA, João Pascoal. Streamlining Acceptance Test Generation for Mobile Applications Through Large Language Models: An Industrial Case Study. arXiv:2510.18861, 2025.

O trabalho ataca o custo de criar e manter artefatos de teste de aceitação em aplicações móveis multiplataforma, atividade que permanece manual mesmo em equipes que já usam automação. Resolve o problema com o AToMIC, um arcabouço que recebe a tarefa do Jira e as alterações de código recentes e produz, em sequência, os cenários Gherkin, os Page Objects e os roteiros de interface executáveis, empregando modelos de linguagem executados localmente. A validação foi feita no aplicativo MyBMW, uma base Flutter com mais de 170 telas, sobre treze tarefas reais vinculadas a 67 commits, medindo qualidade dos artefatos, tempo de geração e consumo de tokens, e complementada por survey com os profissionais do projeto: 93,3% dos cenários Gherkin saíram sintaticamente corretos, 78,8% dos Page Objects rodaram sem edição manual e 100% dos testes de interface executaram. Ficou faltando qualquer tratamento do valor esperado — a verificação é de sintaxe e de execução do roteiro, nunca do resultado de negócio, de modo que não há oráculo de dados. Também não utiliza documentação funcional como segunda fonte de contexto, apoiando-se em alterações de código, o que restringe a cobertura ao que a tarefa alterou e deixa de fora os comportamentos que a rotina já deveria apresentar. A amostra de treze tarefas é pequena e o estudo se restringe a um único aplicativo e a uma única tecnologia.

2 Spider 2.0 — desempenho de modelos em bases corporativas reais

LEI, Fangyu et al. Spider 2.0: Evaluating Language Models on Real-World Enterprise Text-to-SQL Workflows. In: International Conference on Learning Representations (ICLR), 2025.

O trabalho parte da constatação de que os benchmarks de tradução de linguagem natural para SQL usam esquemas pequenos e perguntas de uma única consulta, o que superestima a competência dos modelos e não representa o ambiente corporativo. Resolve o problema construindo um novo conjunto de avaliação com 632 problemas derivados de casos de uso empresariais reais, com bases que ultrapassam mil colunas, múltiplos dialetos e operações encadeadas de transformação e análise. A validação consistiu em submeter um arcabouço de agente de código sobre o modelo o1-preview a esse conjunto e comparar o resultado com os benchmarks anteriores: apenas 21,3% das tarefas foram resolvidas, contra 91,2% no Spider 1.0 e 73,0% no BIRD. Ficou faltando propor qualquer mecanismo de verificação do resultado produzido — o trabalho mede a queda de desempenho, mas não oferece caminho para tornar utilizável a saída de um modelo nesse cenário, que é exatamente a lacuna que o presente trabalho ocupa.

3 Acurácia por execução — como julgar se uma consulta gerada está correta

ZHONG, Ruiqi; YU, Tao; KLEIN, Dan. Semantic Evaluation for Text-to-SQL with Distilled Test Suites. In: Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020. p. 396-411.

O trabalho enfrenta um problema de medição: comparar a consulta gerada com a consulta de referência por igualdade de texto produz falsos negativos, porque duas consultas escritas de formas diferentes podem ser semanticamente equivalentes; e comparar apenas executando ambas sobre uma única base produz falsos positivos, porque consultas distintas podem coincidir por acaso naqueles dados. Resolve o problema destilando, a partir de muitas bases geradas aleatoriamente, um pequeno conjunto de bases de teste com alta cobertura da consulta de referência, e passando a medir a acurácia pela igualdade dos conjuntos de resultado sobre esse conjunto. A validação se deu pela aplicação da métrica a 21 modelos submetidos ao ranking do Spider, com conferência manual de cem exemplos: a métrica anterior apresentava 2,5% de falso negativo em média e 8,1% no pior caso, e a nova se tornou oficial no Spider, no SParC e no CoSQL. Ficou faltando aplicabilidade a ambientes com massa real — o método depende de gerar bases sintéticas, o que não se aplica a um ambiente de homologação com dados corporativos, embora a ideia central de comparar conjuntos de resultado, e não textos de consulta, seja transponível.

4 Debate entre múltiplas instâncias — concordância como redução de erro

DU, Yilun et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate. In: International Conference on Machine Learning (ICML), PMLR v. 235, 2024. p. 11733-11763.

O trabalho trata da fragilidade de aceitar uma única saída de um modelo de linguagem, sujeita a erro factual e a encadeamento de raciocínio inconsistente. Resolve o problema com um procedimento em que várias instâncias de modelo propõem respostas de forma independente e depois confrontam as respostas umas das outras ao longo de rodadas sucessivas, até convergirem para uma resposta comum. A validação foi feita sobre tarefas de aritmética, matemática de nível escolar, conhecimento geral e geração de biografias, comparando o desempenho do procedimento com o de uma única geração e com estratégias de prompting anteriores, e verificando tanto o acerto quanto a redução de afirmações falaciosas. Ficou faltando isolar o efeito da diversidade de origem: o experimento usa múltiplas instâncias de um mesmo modelo, e não modelos de famílias distintas, de modo que a hipótese de que origens diferentes reduzem erro correlacionado permanece plausível mas não demonstrada — hipótese que o presente trabalho testa empiricamente ao medir a taxa de falso acordo entre três modelos de famílias distintas. O custo computacional também cresce com o número de instâncias e de rodadas, o que o trabalho reconhece sem quantificar em termos financeiros.

5 Qualidade de cenários BDD — sobre qual critério julgar um cenário

OLIVEIRA, Gabriel; MARCZAK, Sabrina; MORALLES, Cassiano. How to Evaluate BDD Scenarios' Quality? In: Simpósio Brasileiro de Engenharia de Software (SBES), 2019. p. 481-490.

O trabalho parte da ausência de um instrumento consolidado para julgar se um cenário BDD é bom, o que deixa a revisão dos cenários dependente do julgamento pessoal de cada revisor e dificulta comparações entre equipes. Resolve o problema identificando e organizando os atributos que caracterizam um cenário de qualidade: clareza, isto é, ser compreensível por todos os envolvidos, incluindo os não técnicos; testabilidade, isto é, permitir conversão direta em teste; concisão, isto é, ausência de ambiguidade e de redundância; e valor, isto é, refletir uma necessidade real do usuário. A validação foi conduzida por estudo empírico com profissionais, e trabalho posterior dos mesmos autores converteu os atributos em uma lista de verificação aplicável por profissionais iniciantes em BDD. Ficou faltando cobrir cenários produzidos por máquina: o instrumento foi concebido e validado sobre cenários escritos por pessoas, e não há evidência de que os quatro atributos sejam suficientes para capturar as falhas típicas de uma saída gerada por modelo de linguagem, como a omissão de comportamentos não mencionados no requisito.

OBSERVAÇÕES SOBRE ESTA ENTREGA

Registro, conforme combinado, o que ficou incompleto e por quê:

1. O levantamento partiu das referências da proposta, ampliadas por rastreamento das listas de referências desses trabalhos e por consulta à SBC OpenLib. Não foram definidas cadeias de busca formais nem registradas contagens por base, de modo que a etapa não constitui uma revisão sistemática.
2. Fonseca et al. (2025) e Ferreira et al. (2025) são pré-prints. Há versão publicada do primeiro no IEEE Xplore, documento 11334650, cujo veículo ainda preciso confirmar.
3. Quatro referências herdadas da proposta (Solis e Wang, 2011; Karpurapu et al., 2024; Li et al., 2023; Arredondo-Reyes et al., 2023) ainda não tiveram os DOIs reabertos para conferência de paginação.

PONTO PARA A ORIENTAÇÃO

O levantamento trouxe um achado que afeta o enquadramento do trabalho. O AToMIC (ficha 1) já gera cenários Gherkin a partir de tarefas do Jira e foi avaliado em ambiente industrial, o que significa que a integração com a ferramenta de gestão e a geração do cenário a partir do requisito, que eu tratava como diferencial, já estão cobertas pela literatura. Permanecem como diferenciais do meu módulo de geração o uso da documentação funcional da rotina como segunda fonte, para cobrir comportamentos que o requisito não menciona, e o recorte em sistema de gestão empresarial. São diferenciais reais, mas de menor peso.

Minha leitura, portanto, é que devo declarar essa sobreposição explicitamente na fundamentação e concentrar a contribuição no segundo módulo: a apuração do valor esperado por consulta ao banco de dados, com decisão por consenso entre modelos de famílias distintas. Não encontrei trabalho equivalente. O mais próximo é Mendoza et al. (2024), que gera dados de teste sintéticos a partir de cenários BDD — o inverso do que proponho, já que trabalho sobre a massa de dados que já existe no ambiente e apuro qual valor o sistema deve apresentar. Gostaria de tratar desse reposicionamento na orientação.