E5 — PLANO DE VALIDAÇÃO

Eduardo Krause (RA 12520157) — Análise e Desenvolvimento de Sistemas — UNIMATER
Orientador: Prof. Me. João Mazzochin — Entrega de 13/10/2026

Este documento define como o trabalho será provado antes que a plataforma exista: métricas, linhas de base, protocolo do experimento e instrumentos de coleta. Cada objetivo específico da proposta está amarrado a pelo menos uma métrica, e cada métrica tem unidade, forma de coleta e valor esperado definidos de antemão. Incorpora os pontos 1, 3, 4, 5 e 6 da avaliação da proposta: a distinção entre valor apurado e validado, os critérios de inclusão fixados antes da coleta, a rubrica de aceitação, o teste de significância do tempo e as limitações de generalização. O conteúdo corresponde à subseção 3.4 do artigo.

1 Tipo de validação

Em coerência com a Design Science Research adotada na proposta, a avaliação verifica se o artefato resolve o problema para o qual foi construído, no ambiente em que será usado (HEVNER et al., 2004; PEFFERS et al., 2007). Combina três formas de validação: **experimento com métricas técnicas**, para o Módulo 2, em que os valores apurados são confrontados com consultas de referência; **avaliação por especialistas**, para o Módulo 1, em que quatro analistas de qualidade da equipe, excluído o autor, julgam os cenários gerados; e **comparação pareada com o processo atual**, em que o tempo de elaboração do caso de teste é medido com e sem a plataforma sobre as mesmas tarefas.

Uma distinção orienta as métricas do Módulo 2. A execução no banco garante que o valor é **apurado**: existe nos dados, é rastreável e reprodutível. Não garante que seja **validado**, isto é, que a consulta represente a regra de negócio. A avaliação mede essa distância diretamente: a acurácia (M9) compara o valor consensuado com uma consulta de referência conferida no próprio relatório do sistema, e a taxa de falso acordo (M11) conta os casos em que os modelos concordam em uma consulta que não representa a regra.

2 Objetivos específicos e métricas

O Quadro 1 associa cada objetivo específico às métricas que o verificam, definidas no Quadro 2.

Quadro 1 – Objetivos específicos e métricas associadas

Objetivo específico	Métricas	Pergunta que a métrica responde
OE1 — Caracterizar o processo atual de elaboração de casos de teste	M1, M2 (procedimento atual)	Com que frequência a apuração de valores aparece, e quanto tempo o procedimento atual consome?
OE2 — Implementar a geração de cenários a partir do requisito e da documentação	M3, M7	Os cenários são válidos, e a documentação funcional amplia a cobertura dos comportamentos da rotina?
OE3 — Implementar a apuração por múltiplos modelos com decisão por consenso	M8, M10, M13	Os modelos concordam, quanto cada um acerta isoladamente, e a que custo?
OE4 — Avaliar a qualidade dos cenários e a acurácia dos valores	M2, M4, M5, M6, M9, M11, M12	Os cenários são aceitos, os valores consensuados estão corretos, e quando o consenso engana?

Fonte: elaborado pelo autor (2026).

3 Métricas

Os valores esperados do Quadro 2 são hipóteses fixadas antes da coleta. Onde a literatura oferece referência, ela é indicada; os demais serão revistos apenas com base no teste-piloto, nunca após os resultados do experimento.

Quadro 2 – Métricas da avaliação

ID	Métrica	O que mede	Como é coletada	Unidade	Valor esperado
M1	Incidência de apuração	Proporção das tarefas do acervo que exigem valor esperado obtido no banco	Classificação manual de amostra aleatória de 100 tarefas do acervo	%	Descritiva (caracterização)
M2	Tempo de elaboração	Tempo para produzir o caso de teste pronto para execução, no procedimento atual e com a plataforma	Cronometragem por sessão, registrada na planilha do Apêndice B	min por tarefa	Redução mediana ≥ 30%, significativa a 5%
M3	Validade sintática	Proporção de arquivos de cenários aceitos pelo analisador Gherkin na primeira geração	Automática, pelo registro de execuções	%	≥ 90% (93,3% em Fonseca, Lima e Faria, 2025)
M4	Aceitação dos cenários	Distribuição das decisões: aceito sem alteração, aceito com alteração menor, rejeitado	Ficha de avaliação (Apêndice A) com a rubrica do Quadro 4, dois analistas por tarefa	% de tarefas	≥ 60% aceitas, com ou sem alteração (68% em Ferreira et al., 2025)
M5	Qualidade percebida	Clareza, testabilidade, concisão e valor dos cenários (OLIVEIRA; MARCZAK; MORALLES, 2019)	Ficha de avaliação, escala de 1 a 5 por atributo	média (1–5)	≥ 4,0 em cada atributo
M6	Cobertura do caso de referência	Proporção dos itens verificados no caso do analista que os cenários gerados também verificam; e itens adicionais válidos	Ficha de avaliação, item a item	% e contagem	≥ 70% de cobertura
M7	Completude frente à documentação	Proporção dos comportamentos documentados da rotina cobertos pelos cenários	Lista de comportamentos preparada antes da geração; comparação com e sem documentação	%	Superior à versão sem documentação
M8	Concordância	Distribuição dos desfechos:	Automática, pelo registro	% de	Divergente + falha ≤

ID	Métrica	O que mede	Como é coletada	Unidade	Valor esperado
	entre modelos	unânime, maioria, divergente e falha	de execuções	apurações	25%
M9	Acurácia do consenso	Proporção das apurações com valor de referência cujo resultado coincide com o da consulta de referência	Comparação dos conjuntos normalizados	%	≥ 80% e superior a M10
M10	Acurácia individual	A mesma medida, para cada modelo isolado	Comparação dos conjuntos normalizados	% por modelo	Linha de base de M9
M11	Falso acordo	Proporção das apurações com consenso em que o resultado consensuado diverge da referência	Comparação dos conjuntos normalizados	%	≤ 10%
M12	Valores alterados na conferência	Proporção dos valores apurados que o analista corrige antes de executar o teste	Tela de revisão (REVISAO.valores_alterados)	%	≤ 10%
M13	Custo e tempo por apuração	Custo em tokens dos três modelos, convertido pela tabela de preços vigente, e tempo total	Automática, pelo registro de execuções	US$ e s	≤ US$ 0,10 e ≤ 60 s

Fonte: elaborado pelo autor (2026).

4 Linhas de base

Cada comparação tem uma linha de base explícita, apresentada no Quadro 3. A mais importante é o **procedimento atual da equipe**, que já emprega ferramentas de propósito geral com fornecimento manual de contexto. Comparar com ele, e não com uma elaboração inteiramente manual, é a escolha mais exigente: a plataforma precisa superar o que a equipe já faz com apoio de modelos, e não um cenário que deixou de existir.

Quadro 3 – Linhas de base da avaliação

Linha de base	O que isola	Métricas
Procedimento atual da equipe, com ferramentas de propósito geral	O ganho de usar a plataforma no trabalho real	M2, M6
A própria plataforma sem a documentação funcional (ablação)	A contribuição da segunda fonte de contexto, diferencial do Módulo 1	M6, M7
Cada modelo isolado	O ganho do consenso sobre o melhor modelo sozinho	M9 × M10
Consulta de referência validada por analista	A correção do valor apurado	M9, M10, M11
Resultados publicados (FONSECA; LIMA; FARIA, 2025; FERREIRA et al., 2025)	Ordem de grandeza esperada; não há comparação direta	M3, M4

Fonte: elaborado pelo autor (2026).

5 Protocolo do experimento

O protocolo foi escrito para que outra pessoa, com acesso ao mesmo ambiente, consiga repeti-lo. Todos os dados brutos são registrados desde o teste-piloto: as execuções na base local da plataforma e as avaliações e tempos em planilha.

5.1 Preparação do ambiente

- Fixar as versões dos três modelos e a temperatura zero, onde o provedor permitir, e registrar ambas.
- Versionar os *prompts* no repositório; cada execução grava a versão usada.
- Executar todas as consultas, da plataforma e de referência, na mesma janela de tempo e com o mesmo usuário somente leitura. Ao final, reexecutar as consultas de referência: se algum resultado mudar, os dados foram atualizados durante o experimento e o caso é descartado e relatado.
- Registrar a tabela de preços de cada provedor na data da execução.

5.2 Conjunto 1: tarefas para o Módulo 1

Os critérios de seleção ficam fixados nesta data, antes de qualquer coleta, e são registrados no Apêndice E. O acervo é o projeto do sistema estudado na ferramenta de gestão de tarefas, e é elegível a tarefa que atende a todos os critérios de inclusão:

- **I1** — é do tipo melhoria, *bug* ou tarefa, está com situação Finalizada e foi concluída entre 01/01/2025 e 30/09/2026;
- **I2** — o campo que registra a rotina afetada, com o caminho de menu, cita a área de estoque ou a de vendas, mas não as duas, para que cada tarefa pertença a uma única área;
- **I3** — o campo Casos de teste, preenchido pelo analista, não está vazio;
- **I4** — o requisito tem descrição textual de ao menos 50 palavras, e não apenas título;
- **I5** — a rotina afetada possui página de documentação funcional revisada.

E é excluída a tarefa que se enquadra em qualquer critério de exclusão:

- **E1** — não tem comportamento funcional verificável, como ajustes de infraestrutura ou de desempenho;
- **E2** — duplica outra tarefa já selecionada;
- **E3** — teve o caso de referência elaborado pelo próprio autor, para que ele não avalie, ainda que indiretamente, o próprio trabalho.

Os critérios I1 a I3 são aplicados por consulta ao Jira sobre todo o acervo. Os demais exigem a leitura de cada tarefa e são aplicados às tarefas em ordem aleatória, definida por semente registrada, até se obterem 18 elegíveis por área: três para a calibração da rubrica e 15 para a avaliação. O relatório final informa o total disponível, quantas tarefas foram examinadas, quantas cada critério eliminou e quantas foram selecionadas, de modo a mostrar que a seleção não recaiu apenas sobre casos favoráveis. Antes de qualquer geração, o autor extrai da documentação de cada rotina a lista de comportamentos esperados, conferida por um analista, que serve de referência para M7.

5.3 Conjunto 2: perguntas para o Módulo 2

São considerados todos os relatórios e consultas das duas áreas, sem amostragem. Para cada um, formulam-se de uma a três perguntas de negócio, cada qual com a consulta SQL de referência. As consultas de referência são escritas pelo autor **antes** de qualquer execução da plataforma e conferidas por um analista, que executa a consulta e confirma o valor no próprio relatório do sistema.

5.4 Execução do Módulo 2

Cada pergunta é submetida uma vez à plataforma completa, que registra os três candidatos, as verificações, o desfecho e os custos. M8 a M11 e M13 são calculadas a partir desse registro, aplicando à consulta de referência a mesma normalização aplicada aos candidatos. Para medir a variação causada pela não determinação dos modelos (SALLOU; DURIEUX; PANICHELLA, 2024), um subconjunto de dez perguntas é executado três vezes, e relata-se quantos desfechos mudaram entre as repetições.

5.5 Avaliação dos cenários pelos analistas

Para cada tarefa, a plataforma gera duas versões: a completa e a sem documentação. Cada versão completa é avaliada por dois analistas, de forma independente, na ficha do Apêndice A; com 30 tarefas e quatro analistas, cada um avalia 15. A concordância entre os dois avaliadores de cada tarefa na decisão de M4 é medida pelo coeficiente kappa de Cohen, e as divergências são resolvidas em conversa entre eles, registrando-se a decisão final. Para M7, um terceiro analista

recebe as duas versões em ordem aleatória, identificadas apenas como A e B, e marca os comportamentos cobertos por cada uma.

Para que a aceitação não dependa da interpretação de cada analista, as três categorias de M4 seguem a rubrica do Quadro 4. O critério que separa as duas primeiras é a intenção do cenário: a alteração é menor quando o que é testado continua o mesmo.

Quadro 4 – Rubrica de aceitação dos cenários

Categoria	Critério	Exemplos
Aceito sem alteração	O analista executaria os cenários como estão	Nenhuma mudança
Aceito com alteração menor	Ajustes que não mudam o que é testado: nenhum cenário incluído ou removido e nenhum passo Então com resultado esperado diferente	Corrigir redação ou ortografia; renomear um passo; trocar o código de produto do exemplo por outro equivalente; reordenar cenários
Rejeitado	Mudança no que é testado, ou defeito que impede a execução	Incluir cenário para comportamento omitido; remover cenário fora do escopo; corrigir resultado esperado; passo ambíguo ou não executável (SOARES et al., 2023)

Fonte: elaborado pelo autor (2026).

Antes da avaliação, os quatro analistas aplicam a rubrica a uma mesma amostra de seis tarefas, e a concordância entre eles é medida pelo kappa de Fleiss. Valor abaixo de 0,60 indica que a rubrica ainda admite leituras diferentes: as divergências são discutidas, os exemplos do Quadro 4 são ampliados e a calibração é repetida com outras seis tarefas antes de seguir. As tarefas de calibração não entram no cálculo das métricas.

5.6 Comparação pareada de tempo

As 30 tarefas do Conjunto 1 são preparadas duas vezes: uma pelo procedimento atual e outra com a plataforma, incluindo a conferência dos cenários e valores. Para evitar que o ganho da repetição seja atribuído à plataforma, as duas preparações de uma mesma tarefa são feitas por analistas diferentes, e nenhum analista prepara tarefa cujo caso original tenha elaborado. A atribuição é balanceada: cada analista faz 15 sessões, sete ou oito em cada condição, alternando a ordem das condições entre os analistas. O tempo começa quando a tarefa é aberta e termina quando o caso de teste está pronto para execução.

A diferença de tempo é calculada por tarefa. Se as diferenças tiverem distribuição normal pelo teste de Shapiro-Wilk, aplica-se o teste *t* pareado, com o tamanho do efeito pelo *d* de Cohen para dados pareados; caso contrário, o teste de postos sinalizados de Wilcoxon, com o tamanho do efeito pela correlação bisserial de postos. A diferença é considerada significativa com $p < 0,05$, e relatam-se a mediana das diferenças e seu intervalo de confiança de 95%. Se a disponibilidade dos analistas não permitir as 60 sessões, a medição é reduzida a 12 tarefas sorteadas, mantendo o desenho, e a redução é relatada como limitação.

5.7 Participantes e cuidados éticos

Participam quatro analistas de qualidade da equipe, convidados individualmente, com participação voluntária e em horário de trabalho autorizado pela gestão. Cada um assina o termo de consentimento do Apêndice C e é identificado nos dados apenas por código (A1 a A4). O autor conduz as sessões, mas não avalia cenários nem tem seus casos incluídos no conjunto de referência. Nenhum dado pessoal da base é enviado aos modelos: as colunas com esse tipo de dado ficam em lista de bloqueio do amostrador.

5.8 Análise dos dados

Todas as métricas são apresentadas por estatística descritiva, com mediana e intervalo interquartil para tempos e custos. Além do teste de M2 (seção 5.6) e dos coeficientes kappa de M4, a comparação entre M9 e o melhor resultado de M10 usa o teste de McNemar sobre as mesmas perguntas, desde que haja ao menos 20 perguntas com consenso; abaixo disso, a comparação é apenas descritiva. Os dados brutos são publicados em forma anonimizada no repositório.

6 Ameaças à validade e limitações

Quadro 5 – Ameaças à validade e tratamentos

Ameaça	Tratamento
O autor integra a equipe e construiu a plataforma	Avaliação feita apenas pelos outros quatro analistas; casos do autor excluídos (E3); consultas de referência escritas antes das execuções
Conjunto de referência elaborado com apoio de ferramentas de propósito geral	Declarado como representativo do procedimento atual, e não como referência isenta de assistência

Ameaça	Tratamento
Aprendizado entre sessões na comparação de tempo	Cada analista nunca repete uma tarefa; atribuição cruzada entre as condições
Julgamento subjetivo da aceitação	Definição operacional das categorias, dois avaliadores por tarefa e kappa relatado
Falso positivo na comparação por execução	Medido diretamente por M11; normalização documentada
Mudança de versão ou de comportamento dos modelos	Versões fixadas e registradas; repetição de dez perguntas
Generalização limitada	Duas áreas de um único sistema, que compartilham parte do esquema; registrado como limitação

Fonte: elaborado pelo autor (2026).

A limitação de maior consequência é a generalização. Estoque e vendas compartilham parte do modelo de dados, de modo que as perguntas do Conjunto 2 percorrem tabelas e junções semelhantes. Os resultados permitem afirmar como a plataforma se comporta nessas duas áreas, desse sistema, com essa equipe. Não permitem afirmar o mesmo desempenho em áreas com regras de natureza diferente, como a fiscal e a contábil citadas na justificativa, em outros ERPs ou com analistas de outras equipes. Essas extrapolações serão tratadas como hipóteses para trabalhos futuros, e não como conclusões.

7 Cronograma da validação

Quadro 6 – Cronograma da validação

Período	Atividade
até 20/10/2026	Teste-piloto do protocolo (seção 8) e revisão das instruções
até 10/11/2026	Seleção do Conjunto 1, listas de comportamentos e consultas de referência do Conjunto 2, em paralelo ao desenvolvimento
11/11 a 17/11/2026	Execução do Módulo 2 sobre o Conjunto 2 e primeira rodada de avaliação, como resultado preliminar para a banca
fevereiro e março de 2027	Experimento completo: avaliação dos 30 cenários, comparação pareada de tempo e análise

Fonte: elaborado pelo autor (2026).

Os conjuntos de referência não dependem da plataforma e são montados enquanto ela é desenvolvida. Assim, se a implementação atrasar, a banca de validação ainda recebe o protocolo executado sobre o que estiver pronto, com dados reais, e não apenas a sua descrição.

8 Teste-piloto do protocolo

Como a plataforma ainda não existe, o piloto simula o protocolo manualmente, com o próprio autor no papel de analista, para descobrir instruções ambíguas e estimar a duração das sessões. Usa duas tarefas, uma de cada área, e três perguntas de negócio:

1. aplicar os critérios I1 a I5 e E1 a E3 às duas tarefas e anotar qualquer critério difícil de decidir;
2. gerar os cenários colando requisito e documentação nas interfaces de conversa dos três modelos, com o rascunho do *prompt*, e preencher a ficha do Apêndice A cronometrando o tempo;
3. para cada pergunta, obter uma consulta de cada modelo, executá-la com o usuário somente leitura, aplicar à mão as regras de normalização e decidir o desfecho;
4. comparar com a consulta de referência escrita antes e registrar tudo no Apêndice D.

O piloto será executado até 20/10/2026. Seus resultados são registrados no Apêndice D e orientam a revisão das instruções antes da E6.

Referências

FERNANDES, H.; PERKUSICH, M.; ALBUQUERQUE, D.; SILVA, I.; SANTOS, D. F. S.; GORGÔNIO, K.; PERKUSICH, A. A Comparative Study of LLMs for Gherkin Generation. In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 39., 2025, Recife. **Anais** [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 171-181. DOI: 10.5753/sbes.2025.9888.

FERREIRA, M.; VIEGAS, L.; FARIA, J. P.; LIMA, B. Acceptance Test Generation with Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATION OF SOFTWARE TEST (AST), 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/AST66626.2025.00007.

FONSECA, P. L.; LIMA, B.; FARIA, J. P. Streamlining Acceptance Test Generation for Mobile Applications Through Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATED SOFTWARE ENGINEERING (ASE), 40., 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/ASE63991.2025.00273.

HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. Design Science in Information Systems Research. **MIS Quarterly**, v. 28, n. 1, p. 75-105, 2004. DOI: 10.2307/25148625.

OLIVEIRA, G.; MARCZAK, S.; MORALLES, C. How to Evaluate BDD Scenarios' Quality? In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 33., 2019, Salvador. **Anais** [...]. New York: ACM, 2019. p. 481-490. DOI: 10.1145/3350768.3351301.

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A Design Science Research Methodology for Information Systems Research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45-77, 2007. DOI: 10.2753/MIS0742-1222240302.

SALLOU, J.; DURIEUX, T.; PANICHELLA, A. Breaking the Silence: the Threats of Using LLMs in Software Engineering. In: INTERNATIONAL CONFERENCE ON SOFTWARE ENGINEERING: NEW IDEAS AND EMERGING RESULTS (ICSE-NIER), 46., 2024, Lisboa. **Proceedings** [...]. New York: ACM, 2024. p. 102-106. DOI: 10.1145/3639476.3639764.

SOARES, E.; ARANDA, M.; OLIVEIRA, N.; RIBEIRO, M.; GHEYI, R.; SOUZA, E.; MACHADO, I.; SANTOS, A.; FONSECA, B.; BONIFÁCIO, R. Manual Tests Do Smell! Cataloging and Identifying Natural Language Test Smells. In: ACM/IEEE INTERNATIONAL SYMPOSIUM ON EMPIRICAL SOFTWARE ENGINEERING AND MEASUREMENT (ESEM), 2023. **Proceedings** [...]. IEEE, 2023. p. 1-11.

Apêndice A — Ficha de avaliação de cenários

Avaliador: A__ Tarefa: _____ Data: ___/___/2026 Início: ___:___ Fim: ___:___

1. Decisão sobre o conjunto de cenários (marque uma)

- ( ) **Aceito sem alteração** — executaria como está.
- ( ) **Aceito com alteração menor** — só redação, nome de passo ou valor de exemplo; nenhum cenário incluído ou removido; nenhum resultado esperado alterado.
- ( ) **Rejeitado** — omite o comportamento central, tem resultado esperado incorreto ou defeito que impede a execução.

2. Atributos de qualidade (1 = discordo totalmente; 5 = concordo totalmente)

Quadro 7 – Escala de qualidade dos cenários

Atributo	Afirmação	1	2	3	4	5
Clareza	Os cenários são compreensíveis por quem não é técnico					
Testabilidade	Cada cenário pode ser executado como teste sem interpretação adicional					
Concisão	Não há ambiguidade nem redundância entre passos e cenários					
Valor	Os cenários verificam o que importa para o usuário da rotina					

Fonte: adaptado de Oliveira, Marczak e Moralles (2019).

3. Cobertura do caso de referência

Quadro 8 – Itens do caso de referência

Item verificado no caso do analista	Coberto pelos cenários gerados?
1.	( ) sim ( ) parcialmente ( ) não
2.	( ) sim ( ) parcialmente ( ) não
3.	( ) sim ( ) parcialmente ( ) não
…	

Fonte: elaborado pelo autor (2026).

Itens **adicionais** propostos pela plataforma que não estão no caso de referência: ____ válidos ____ inválidos.

Valores esperados corrigidos durante a conferência: ____ de ____. Observações: _____

Apêndice B — Registro de tempo da comparação pareada

Quadro 9 – Planilha de registro de tempo

Sessão	Analista	Tarefa	Condição	Início	Fim	Minutos	Observações
S01	A1		atual / plataforma				
S02	A2		atual / plataforma				
…							

Fonte: elaborado pelo autor (2026).

Regras: o tempo começa quando a tarefa é aberta e termina quando o caso de teste está pronto para execução. Interrupções acima de dois minutos são descontadas e anotadas. Nenhum analista prepara a mesma tarefa duas vezes, nem tarefa cujo caso original tenha elaborado.

Apêndice C — Termo de consentimento livre e esclarecido

Você está sendo convidado(a) a participar da avaliação do Trabalho de Conclusão de Curso *Plataforma para geração de cenários de teste em sistemas ERP assistida por modelos de linguagem, com valores esperados verificados em banco de dados*, de autoria de Eduardo Krause, acadêmico do curso de Análise e Desenvolvimento de Sistemas do Centro Universitário Mater Dei (UNIMATER), sob orientação do Prof. Me. João Mazzochin.

O que você fará. Avaliar cenários de teste gerados pela plataforma, em fichas padronizadas, e preparar casos de teste para tarefas já concluídas, com e sem a plataforma, com o tempo cronometrado. A participação estimada é de dez a doze horas, distribuídas em sessões durante o horário de trabalho, com autorização da gestão.

Riscos e cuidados. O risco é mínimo, limitado ao tempo dedicado e a eventual desconforto por ter o tempo medido. O objetivo é avaliar a plataforma, e não o seu desempenho: os resultados nunca serão usados para avaliação profissional, e você será identificado(a) apenas por código (A1 a A4).

Participação voluntária. Você pode recusar ou desistir a qualquer momento, sem qualquer prejuízo e sem precisar justificar. Os dados coletados serão usados exclusivamente neste trabalho e em publicações dele derivadas, sempre de forma anonimizada.

Contato do pesquisador: eduardokrause678@gmail.com. Contato do orientador: joaomazzochin@gmail.com.

Declaro que li e compreendi este termo e aceito participar.

Nome: _____

Assinatura: _____ Data: ___/___/2026

Apêndice D — Registro do teste-piloto

Quadro 10 – Registro do teste-piloto

Item	Resultado
Data de execução	
Tarefas usadas (área)	
Critérios de seleção difíceis de decidir	
Tempo para preencher a ficha do Apêndice A	
Desfechos das três perguntas (unânime, maioria, divergente, falha)	
Resultado consensuado igual ao de referência?	
Regras de normalização que precisaram de ajuste	
Instruções ambíguas encontradas	
Alterações feitas no protocolo	

Fonte: elaborado pelo autor (2026).

Apêndice E — Critérios de seleção registrados antes da coleta

Registrado em 13/10/2026, antes do exame individual de qualquer tarefa para fins de seleção. As contagens de I1 a I3 foram obtidas por consulta ao Jira em 12/10/2026.

Critérios de inclusão: I1 a I5. Critérios de exclusão: E1 a E3 (seção 5.2). Semente do sorteio: 20261030.

Os critérios são aplicados na ordem do quadro, e cada linha conta as tarefas eliminadas apenas por aquele critério. A partir de I4, as contagens referem-se às tarefas examinadas em ordem aleatória. Só são divulgadas contagens: as tarefas selecionadas são identificadas por código (T01 a T30), sem título, cliente ou conteúdo.

Quadro 11 – Funil de seleção das tarefas

Etapa	Estoque	Vendas	Total
Tarefas finalizadas no projeto no período (I1)	—	—	2.913
Rotina cita a área (I2)	276	592	781
(−) citam as duas áreas (I2)	87	87	87
(−) sem casos de teste preenchidos (I3)	0	0	0
Disponíveis após I1 a I3	189	505	694
Examinadas em ordem aleatória			
(−) requisito com menos de 50 palavras (I4)			
(−) rotina sem documentação revisada (I5)			
(−) sem comportamento funcional (E1)			
(−) duplicadas (E2)			
(−) caso de referência elaborado pelo autor (E3)			
Elegíveis obtidas	18	18	36
Calibração da rubrica	3	3	6
Selecionadas por sorteio	15	15	30

Fonte: elaborado pelo autor (2026).