E3 — FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

Eduardo Krause (RA 12520157) — Análise e Desenvolvimento de Sistemas — UNIMATER
Orientador: Prof. Me. João Mazzochin — Entrega de 13/10/2026

Este documento traz o rascunho da Seção 2 do artigo, já no formato do template institucional, e o quadro comparativo que posiciona o trabalho frente à literatura. O texto parte das 40 referências e do fichamento entregues na E2. As referências citadas foram conferidas novamente nas páginas dos editores, o que gerou duas correções em relação à E2, registradas nas observações ao final.

2 Fundamentação Teórica e Trabalhos Relacionados

Esta seção apresenta os conceitos necessários à compreensão da metodologia, as tecnologias empregadas na solução e os trabalhos que tratam de problemas próximos ao investigado, encerrando com a comparação que delimita a contribuição pretendida.

2.1 Conceitos Fundamentais

O desenvolvimento guiado por comportamento (*behavior-driven development*, BDD) é uma abordagem de especificação em que o comportamento esperado do sistema é descrito por exemplos concretos, redigidos em linguagem próxima à do negócio e compartilhados entre analistas, desenvolvedores e testadores (SOLIS; WANG, 2011). Esses exemplos são comumente escritos na notação Gherkin, que organiza cada cenário em passos de contexto (Dado), ação (Quando) e resultado esperado (Então), agrupados por funcionalidade (WYNNE; HELLESOY, 2012; CUCUMBER, 2026). No processo de teste descrito pela ISO/IEC/IEEE 29119-2 (2021), casos de teste são derivados de uma base de teste; neste trabalho, a base é composta pelo requisito da tarefa e pela documentação funcional da rotina. Revisões sistemáticas apontam o esforço de elaborar e manter os cenários como a principal dificuldade do BDD (FAROOQ et al., 2023; ARREDONDO-REYES et al., 2023).

Um caso de teste só tem valor se houver um oráculo, mecanismo que decide se o comportamento observado está correto. Barr et al. (2015) denominam problema do oráculo a dificuldade de obter esse mecanismo e distinguem oráculos especificados,

derivados e implícitos, além do recurso ao julgamento humano quando nenhum deles está disponível. Em relatórios de sistemas de gestão, o oráculo é o valor que o relatório deve exibir para a massa de dados existente, hoje apurado manualmente pelo analista. A proposta substitui essa apuração por um oráculo derivado: o valor é obtido pela execução de consultas sobre os dados armazenados.

Convém distinguir dois atributos do valor obtido dessa forma. O valor é **apurado** quando provém da execução de uma consulta sobre os dados armazenados, sendo rastreável e reprodutível; é **validado** quando a consulta representa corretamente a regra de negócio que o relatório implementa. A execução assegura o primeiro atributo, mas não o segundo: uma consulta pode executar sem erro, retornar dados reais e ainda calcular outra coisa. A plataforma garante a apuração; a validação depende do consenso entre modelos, como indicador de confiança, e da conferência do analista, como decisão final.

Modelos de linguagem de grande porte passaram a ser aplicados a praticamente todas as atividades da engenharia de software (HOU et al., 2024), inclusive ao teste (WANG et al., 2024). A limitação central para o problema aqui tratado é a alucinação, isto é, a produção de conteúdo fluente e plausível, porém infiel aos fatos ou à fonte (HUANG et al., 2025). Em engenharia de software, ela se manifesta em artefatos que aparentam correção sem tê-la, agravada pela não determinação das saídas e pela substituição frequente das versões dos modelos, que comprometem a reprodutibilidade (SALLOU; DURIEUX; PANICHELLA, 2024). Uma das estratégias de mitigação é ancorar a geração em conteúdo recuperado de fonte externa no momento da consulta (LEWIS et al., 2020; HUANG et al., 2025), papel que, na solução, cabe ao requisito, à documentação da rotina e ao catálogo do banco de dados.

A apuração dos valores esperados apoia-se na tradução de perguntas em linguagem natural para consultas SQL (*text-to-SQL*). No conjunto Spider (YU et al., 2018), abordagens baseadas em modelos de linguagem superam 85% de acurácia por execução (POURREZA; RAFIEI, 2023; GAO et al., 2024). O desempenho cai quando esquema e dados se aproximam dos corporativos: no BIRD, com 95 bancos e 33,4 GB de dados, o ChatGPT atingiu 40,08% de acurácia por execução, contra 92,96% de

especialistas humanos (LI et al., 2023); no Spider 2.0, com 632 problemas derivados de fluxos de trabalho empresariais, o melhor agente avaliado resolveu 21,3% das tarefas (LEI et al., 2025). A acurácia por execução considera correta a consulta cujo conjunto de resultado coincide com o da consulta de referência. Zhong, Yu e Klein (2020) mostram que esse critério evita os falsos negativos da comparação textual, de 2,5% em média e 8,1% no pior caso, mas que, executado sobre uma única base, admite falsos positivos, quando consultas distintas coincidem por acaso nos dados disponíveis. Neste trabalho, a comparação de conjuntos de resultado é o critério para decidir se dois modelos concordam, e o risco de falso positivo corresponde ao falso acordo: modelos que concordam em uma consulta que não representa a regra de negócio. A taxa de falso acordo mede, portanto, a distância entre valor apurado e valor validado.

Por fim, a decisão por concordância apoia-se em resultados que mostram ganho ao substituir uma única saída pela mais frequente entre várias. Wang et al. (2023) amostram diversos raciocínios de um mesmo modelo e adotam a resposta majoritária, estratégia denominada autoconsistência, com ganho de 17,9 pontos percentuais no conjunto GSM8K. Du et al. (2024) fazem múltiplas instâncias debaterem suas respostas até convergirem, o que reduz afirmações falaciosas; seus experimentos principais usam instâncias de um mesmo modelo, e apenas um experimento reduzido, com 20 problemas, combina modelos de famílias distintas. Como amostras de um mesmo modelo tendem a compartilhar os mesmos erros, a hipótese de que modelos de origens distintas reduzem essa correlação permanece pouco explorada, e é examinada neste trabalho por meio da taxa de falso acordo.

2.2 Tecnologias Envolvidas

Três modelos de linguagem de famílias distintas são empregados: Claude, da Anthropic; Gemini, do Google; e um modelo de pesos abertos da família Llama, acessado pela infraestrutura de inferência da Groq. A distinção de origem é condição para a validade do consenso, e o número três decorre da necessidade de desempate. As versões exatas de cada modelo serão fixadas e registradas antes dos experimentos, em atenção ao risco de reprodutibilidade apontado por Sallou, Durieux e Panichella (2024).

O sistema gerenciador de banco de dados é o MySQL, no qual reside a base de homologação do sistema estudado e do qual provêm os valores de referência. O esquema é extraído das visões do INFORMATION_SCHEMA, que expõem tabelas, colunas, tipos, chaves e restrições de integridade referencial (ORACLE, 2026), e o plano de execução é obtido pelo comando EXPLAIN antes de cada execução. Os cenários seguem a gramática Gherkin (CUCUMBER, 2026), verificada por analisador sintático antes da entrega ao analista.

A camada de orquestração é implementada em Java com o *framework* Spring Boot, escolha que oferece acesso nativo a bancos relacionais e execução concorrente das chamadas aos três modelos; a interface é desenvolvida em React. Requisitos e documentação são lidos das interfaces de programação do Jira e do Confluence, ferramentas de gestão de tarefas e de documentação adotadas pela equipe. Ambas as camadas são empacotadas em um único artefato executado localmente, pois as credenciais de acesso aos modelos e ao banco não podem residir no navegador e o banco corporativo não deve ser exposto à rede externa.

2.3 Trabalhos Relacionados

O Quadro 1 compara os trabalhos mais próximos segundo os critérios que distinguem a proposta: as fontes de entrada, o artefato produzido, a apuração de valores esperados sobre dados reais, o uso de mais de um modelo e o contexto em que a solução foi avaliada.

Quadro 1 – Comparação entre os trabalhos relacionados e a proposta

Trabalho	**Entrada**	**Saída**	**Valor esperado apurado em dados reais**	**Uso de vários modelos**	**Contexto e validação**
Karpurapu et al. (2024)	*User stories* públicas	Cenários Gherkin	Não	Compara quatro modelos, sem combiná-los	Acadêmico; validação sintática dos arquivos gerados
Fernandes et al. (2025)	Descrições livres de casos de teste	Cenários Gherkin	Não	Compara sete modelos, sem combiná-los	Sistema em produção, dez casos; similaridade textual com referência de especialista
Paduraru, Zavelca e Stefanescu (2025)	Descrição em linguagem natural e passos já implementados	Passos Gherkin vinculados ao código	Não	Um modelo ajustado, com agentes	Industrial (jogos); testes sintéticos e estudo qualitativo com profissionais
Ferreira et al. (2025)	*User story* do Jira e HTML das	Gherkin e roteiros Cypress	Não	Um modelo	Industrial (web); utilidade percebida por profissionais

Trabalho	Entrada	Saída	Valor esperado apurado em dados reais	Uso de vários modelos	Contexto e validação
	páginas				
Fonseca, Lima e Faria (2025)	Tarefa do Jira e alterações de código	Gherkin, Page Objects e roteiros de interface	Não	Um modelo por etapa, sem votação	Industrial (aplicativo móvel); sintaxe, execução e percepção de profissionais
Garg e Sharma (2023)	Solicitação do usuário	Casos e cenários de teste	Não	Um modelo	ERP; sem avaliação empírica
Mendoza et al. (2024)	Cenários BDD	Dados de teste sintéticos	Não; gera massa nova	Compara quatro ferramentas, sem combiná-las	Cinco cenários ilustrativos; avaliação qualitativa
Este trabalho	**Requisito do Jira, documentação da rotina e esquema do banco**	**Cenários Gherkin com valores esperados e consultas anexadas**	**Sim, por execução em homologação**	**Três famílias, com decisão por consenso**	**ERP em uso (estoque e vendas); avaliação por analistas e contra conjunto de referência**

Fonte: elaborado pelo autor (2026).

Os dois primeiros trabalhos medem a capacidade de modelos de converter textos em Gherkin. Karpurapu et al. (2024) comparam quatro modelos sobre *user stories* públicas e verificam apenas a sintaxe dos arquivos gerados; Fernandes et al. (2025) comparam sete modelos e três estratégias de *prompt* sobre casos de um sistema em produção, medindo a similaridade com cenários escritos por especialista. Ambos confirmam a viabilidade da geração, mas tratam os modelos como alternativas a escolher, e não como fontes a combinar, e nenhum verifica se o resultado esperado descrito no cenário está correto.

Os três trabalhos seguintes levam a geração ao ambiente industrial. Paduraru, Zavelca e Stefanescu (2025) vinculam passos Gherkin a implementações existentes, com humano no ciclo; Ferreira et al. (2025) partem de *user stories* do Jira e chegam a roteiros Cypress; e Fonseca, Lima e Faria (2025), o trabalho mais próximo, geram cenários, Page Objects e roteiros executáveis a partir de tarefas do Jira e das alterações de código, com 93,3% dos cenários sintaticamente corretos. A integração com a ferramenta de gestão e a geração a partir do requisito, portanto, já estão cobertas pela literatura, e não constituem diferencial desta proposta. O que permanece em aberto é o uso da documentação funcional como segunda fonte, capaz de cobrir os comportamentos que a rotina já deveria apresentar e que o requisito não menciona, e

qualquer forma de oráculo de dados: nesses trabalhos, a verificação incide sobre a sintaxe e a execução do roteiro, nunca sobre o resultado de negócio.

Os dois últimos tocam o domínio e os dados. Garg e Sharma (2023) aplicam IA generativa à modelagem de testes de ERP, mas sem avaliação empírica. Mendoza et al. (2024) comparam ferramentas na geração de dados de teste a partir de cenários BDD, o caminho inverso ao proposto: geram massa sintética, enquanto este trabalho parte da massa existente e apura o valor que o sistema deve apresentar sobre ela.

Diferentemente dos trabalhos apresentados, este trabalho confronta a saída dos modelos com os dados efetivamente armazenados: o valor esperado de cada cenário é apurado pela execução, em ambiente somente leitura, de consultas geradas de forma independente por modelos de três famílias, e só é proposto como referência quando ao menos dois resultados coincidem, cabendo ao analista validá-lo. Articula, assim, duas linhas que a literatura trata em separado, a geração de cenários e a tradução para SQL, e avalia empiricamente essa articulação em um sistema de gestão em uso, medindo inclusive quando o consenso engana.

Referências

ARREDONDO-REYES, V. M.; DOMÍNGUEZ-ISIDRO, S.; SÁNCHEZ-GARCÍA, Á. J.; OCHARÁN-HERNÁNDEZ, J. O. Benefits and Challenges of the Behavior-Driven Development: A Systematic Literature Review. In: INTERNATIONAL CONFERENCE IN SOFTWARE ENGINEERING RESEARCH AND INNOVATION (CONISOFT), 11., 2023. **Anais** [...]. IEEE, 2023. p. 45-54. DOI: 10.1109/CONISOFT58849.2023.00016.

BARR, E. T.; HARMAN, M.; McMINN, P.; SHAHBAZ, M.; YOO, S. The Oracle Problem in Software Testing: A Survey. **IEEE Transactions on Software Engineering**, v. 41, n. 5, p. 507-525, 2015. DOI: 10.1109/TSE.2014.2372785.

CUCUMBER. **Gherkin Reference**. 2026. Disponível em: https://cucumber.io/docs/gherkin/reference/. Acesso em: 9 set. 2026.

DU, Y.; LI, S.; TORRALBA, A.; TENENBAUM, J. B.; MORDATCH, I. Improving Factuality and Reasoning in Language Models through Multiagent Debate. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 41., 2024, Viena. **Proceedings** [...]. PMLR, 2024. v. 235, p. 11733-11763.

FAROOQ, M. S.; OMER, U.; RAMZAN, A.; RASHEED, M. A.; ATAL, Z. Behavior Driven Development: A Systematic Literature Review. **IEEE Access**, v. 11, p. 88008-88024, 2023. DOI: 10.1109/ACCESS.2023.3302356.

FERNANDES, H.; PERKUSICH, M.; ALBUQUERQUE, D.; SILVA, I.; SANTOS, D. F. S.; GORGÔNIO, K.; PERKUSICH, A. A Comparative Study of LLMs for Gherkin Generation. In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 39., 2025, Recife. **Anais** [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 171-181. DOI: 10.5753/sbes.2025.9888.

FERREIRA, M.; VIEGAS, L.; FARIA, J. P.; LIMA, B. Acceptance Test Generation with Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATION OF SOFTWARE TEST (AST), 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/AST66626.2025.00007.

FONSECA, P. L.; LIMA, B.; FARIA, J. P. Streamlining Acceptance Test Generation for Mobile Applications Through Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATED SOFTWARE ENGINEERING (ASE), 40., 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/ASE63991.2025.00273.

GAO, D.; WANG, H.; LI, Y.; SUN, X.; QIAN, Y.; DING, B.; ZHOU, J. Text-to-SQL Empowered by Large Language Models: A Benchmark Evaluation. **Proceedings of the VLDB Endowment**, v. 17, n. 5, p. 1132-1145, 2024. DOI: 10.14778/3641204.3641221.

GARG, A.; SHARMA, D. Generative AI for Software Test Modelling with a focus on ERP Software. In: INTERNATIONAL CONFERENCE ON ADVANCES IN COMPUTATION, COMMUNICATION AND INFORMATION TECHNOLOGY (ICAICCIT), 2023, Faridabad. **Proceedings** [...]. IEEE, 2023. p. 187-193. DOI: 10.1109/ICAICCIT60255.2023.10466102.

HOU, X.; ZHAO, Y.; LIU, Y.; YANG, Z.; WANG, K.; LI, L.; LUO, X.; LO, D.; GRUNDY, J.; WANG, H. Large Language Models for Software Engineering: A Systematic Literature Review. **ACM Transactions on Software Engineering and Methodology**, v. 33, n. 8, art. 220, 2024. DOI: 10.1145/3695988.

HUANG, L.; YU, W.; MA, W.; ZHONG, W.; FENG, Z.; WANG, H.; CHEN, Q.; PENG, W.; FENG, X.; QIN, B.; LIU, T. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. **ACM Transactions on Information Systems**, v. 43, n. 2, art. 42, p. 1-55, 2025. DOI: 10.1145/3703155.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. **ISO/IEC/IEEE 29119-2:2021**: Software and systems engineering — Software testing — Part 2: Test processes. 2. ed. Genebra: ISO, 2021.

KARPURAPU, S.; MYNENI, S.; NETTUR, U.; GAJJA, L. S.; BURKE, D.; STIEHM, T.; PAYNE, J. Comprehensive Evaluation and Insights Into the Use of Large Language Models in the Automation of Behavior-Driven Development Acceptance Test Formulation. **IEEE Access**, v. 12, p. 58715-58730, 2024. DOI: 10.1109/ACCESS.2024.3391815.

LEI, F.; CHEN, J.; YE, Y.; CAO, R.; SHIN, D.; SU, H.; SUO, Z.; GAO, H.; HU, W.; YIN, P.; ZHONG, V.; XIONG, C.; SUN, R.; LIU, Q.; WANG, S.; YU, T. Spider 2.0: Evaluating

Language Models on Real-World Enterprise Text-to-SQL Workflows. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 13., 2025, Singapura. **Proceedings** [...]. OpenReview.net, 2025.

LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 33., 2020. **Proceedings** [...]. Curran Associates, 2020. p. 9459-9474.

LI, J.; HUI, B.; QU, G.; YANG, J.; LI, B.; LI, B.; WANG, B.; QIN, B.; GENG, R.; HUO, N.; ZHOU, X.; MA, C.; LI, G.; CHANG, K.; HUANG, F.; CHENG, R.; LI, Y. Can LLM Already Serve as a Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 36., 2023. **Proceedings** [...]. Datasets and Benchmarks Track. Curran Associates, 2023.

MENDOZA, I.; SILVA FILHO, F.; MEDEIROS, G.; PAES, A.; NEVES, V. O. Comparative Analysis of Large Language Model Tools for Automated Test Data Generation from BDD. In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 38., 2024, Curitiba. **Anais** [...]. Porto Alegre: Sociedade Brasileira de Computação, 2024. p. 280-290. DOI: 10.5753/sbes.2024.3423.

ORACLE. **MySQL 8.4 Reference Manual**: INFORMATION_SCHEMA Tables. 2026. Disponível em: https://dev.mysql.com/doc/refman/8.4/en/information-schema.html. Acesso em: 9 set. 2026.

PADURARU, C.; ZAVELCA, M.; STEFANESCU, A. Agentic AI for Behavior-Driven Development Testing Using Large Language Models. In: INTERNATIONAL CONFERENCE ON AGENTS AND ARTIFICIAL INTELLIGENCE (ICAART), 17., 2025. **Proceedings** [...]. SciTePress, 2025. v. 2, p. 805-815. DOI: 10.5220/0013374400003890.

POURREZA, M.; RAFIEI, D. DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 36., 2023. **Proceedings** [...]. Curran Associates, 2023. p. 36339-36348.

SALLOU, J.; DURIEUX, T.; PANICHELLA, A. Breaking the Silence: the Threats of Using LLMs in Software Engineering. In: INTERNATIONAL CONFERENCE ON SOFTWARE ENGINEERING: NEW IDEAS AND EMERGING RESULTS (ICSE-NIER), 46., 2024, Lisboa. **Proceedings** [...]. New York: ACM, 2024. p. 102-106. DOI: 10.1145/3639476.3639764.

SOLIS, C.; WANG, X. A Study of the Characteristics of Behaviour Driven Development. In: EUROMICRO CONFERENCE ON SOFTWARE ENGINEERING AND ADVANCED APPLICATIONS (SEAA), 37., 2011. **Anais** [...]. IEEE, 2011. p. 383-387. DOI: 10.1109/SEAA.2011.76.

WANG, J.; HUANG, Y.; CHEN, C.; LIU, Z.; WANG, S.; WANG, Q. Software Testing With Large Language Models: Survey, Landscape, and Vision. **IEEE Transactions on Software Engineering**, v. 50, n. 4, p. 911-936, 2024. DOI: 10.1109/TSE.2024.3368208.

WANG, X.; WEI, J.; SCHUURMANS, D.; LE, Q. V.; CHI, E. H.; NARANG, S.; CHOWDHERY, A.; ZHOU, D. Self-Consistency Improves Chain of Thought Reasoning in Language Models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 11., 2023, Kigali. **Proceedings** [...]. OpenReview.net, 2023.

WYNNE, M.; HELLESOY, A. **The Cucumber Book**: Behaviour-Driven Development for Testers and Developers. Raleigh: Pragmatic Bookshelf, 2012.

YU, T.; ZHANG, R.; YANG, K.; YASUNAGA, M.; WANG, D.; LI, Z.; MA, J.; LI, I.; YAO, Q.; ROMAN, S.; ZHANG, Z.; RADEV, D. Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING (EMNLP), 2018, Bruxelas. **Proceedings** [...]. Association for Computational Linguistics, 2018. p. 3911-3921. DOI: 10.18653/v1/D18-1425.

ZHONG, R.; YU, T.; KLEIN, D. Semantic Evaluation for Text-to-SQL with Distilled Test Suites. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING (EMNLP), 2020. **Proceedings** [...]. Association for Computational Linguistics, 2020. p. 396-411. DOI: 10.18653/v1/2020.emnlp-main.29.

Observações sobre esta entrega

1. **Correção em relação à E2.** O fichamento afirmava que Du et al. (2024) usam apenas instâncias de um mesmo modelo. Na releitura, o artigo traz também um experimento reduzido, com 20 problemas do GSM8K, que combina ChatGPT e Bard. O texto acima foi redigido de acordo; a lacuna continua existindo, mas foi enunciada com mais cuidado.
2. **Veículos confirmados.** Fonseca, Lima e Faria (2025) foi publicado no ASE 2025 e Ferreira et al. (2025) no AST 2025; as referências deixaram de apontar para os pré-prints. O DOI de Mendoza et al. (2024) é 10.5753/sbes.2024.3423. O arquivo .bib desta entrega já traz as três correções.
3. **Extensão.** O texto da Seção 2 soma cerca de 1.600 palavras, o equivalente a pouco mais de três páginas no formato institucional, sem contar o quadro. Na consolidação do artigo, a subseção 2.1 é a candidata natural a enxugamento.

4. **Ajuste da proposta.** Os sete pontos da avaliação de 15/09 foram tratados nesta entrega, na E4 e na E5. O documento TCC1_AjustesProposta, enviado junto, lista cada ajuste, quem o pediu e onde foi atendido, e que entra como apêndice da versão final do TCC I. Nesta seção, o ajuste visível é a distinção entre valor apurado e valor validado (2.1), pedida por Rafael Rodrigues Barbosa.

E4 — ARQUITETURA, MODELAGEM E BACKLOG

Eduardo Krause (RA 12520157) — Análise e Desenvolvimento de Sistemas — UNIMATER
Orientador: Prof. Me. João Mazzochin — Entrega de 13/10/2026

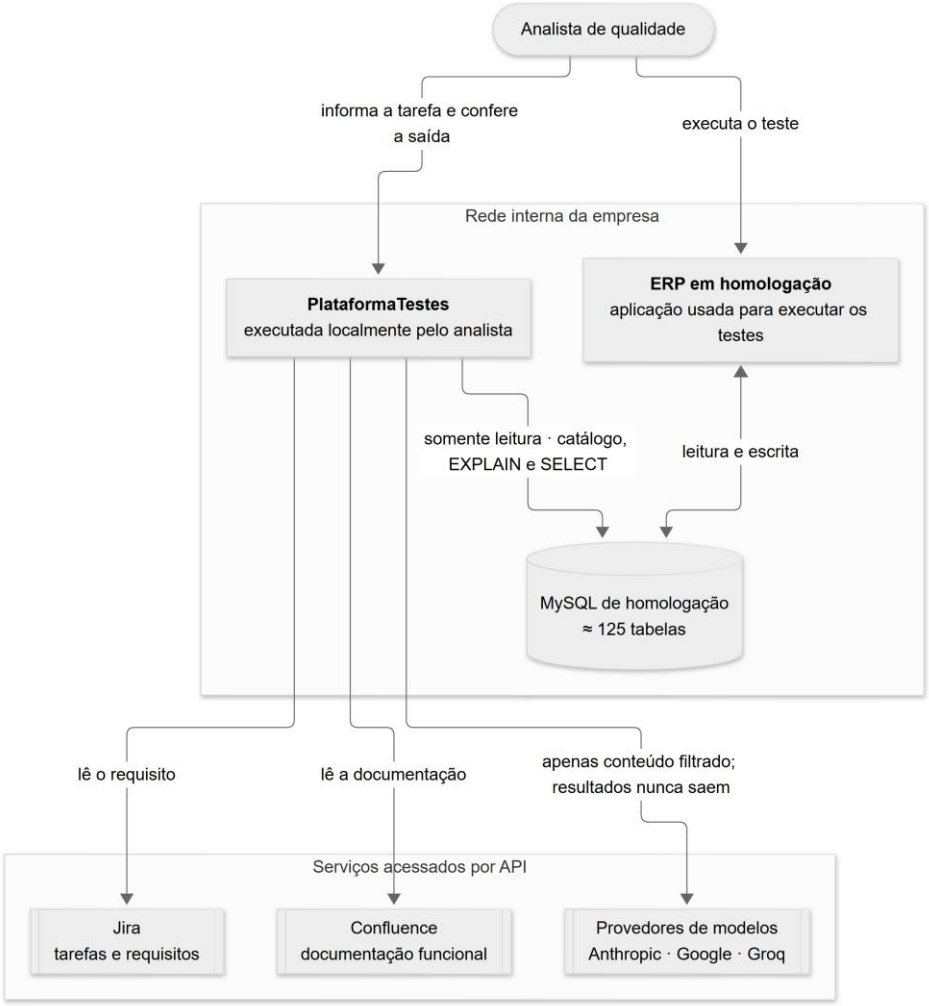
Este documento leva a proposta do papel para o projeto executável: contexto em relação ao ERP, arquitetura, fluxo principal, dados enviados aos provedores de modelos, modelagem dos dados da plataforma, stack justificada e backlog priorizado com a fatia vertical marcada. As seções 1 e 4 atendem a pontos da avaliação da proposta. Os diagramas foram escritos em Mermaid e estão versionados no repositório do projeto, com os mesmos nomes de componentes usados aqui e no código. O conteúdo alimenta as subseções 3.1 a 3.3 do artigo.

1 Contexto: a plataforma e o ERP

O sistema estudado é um ERP web, acessado pelo navegador, com banco de dados MySQL de cerca de 125 tabelas. A avaliação usa o ambiente de homologação, no qual os analistas executam os testes antes de cada entrega semanal. Por confidencialidade, o sistema não é identificado pelo nome.

A Figura 1 mostra onde a plataforma se conecta. Ela não se integra à aplicação do ERP, nem à sua interface ou às suas regras de negócio: lê o banco de homologação em modo somente leitura, o requisito no Jira e a documentação no Confluence. Esse acoplamento restrito ao catálogo e aos dados é o que permite à plataforma operar sobre qualquer área funcional, como afirma a proposta, e a torna independente da tecnologia em que o ERP foi construído.

Figura 1 – Contexto da plataforma em relação ao ERP e aos serviços que consulta

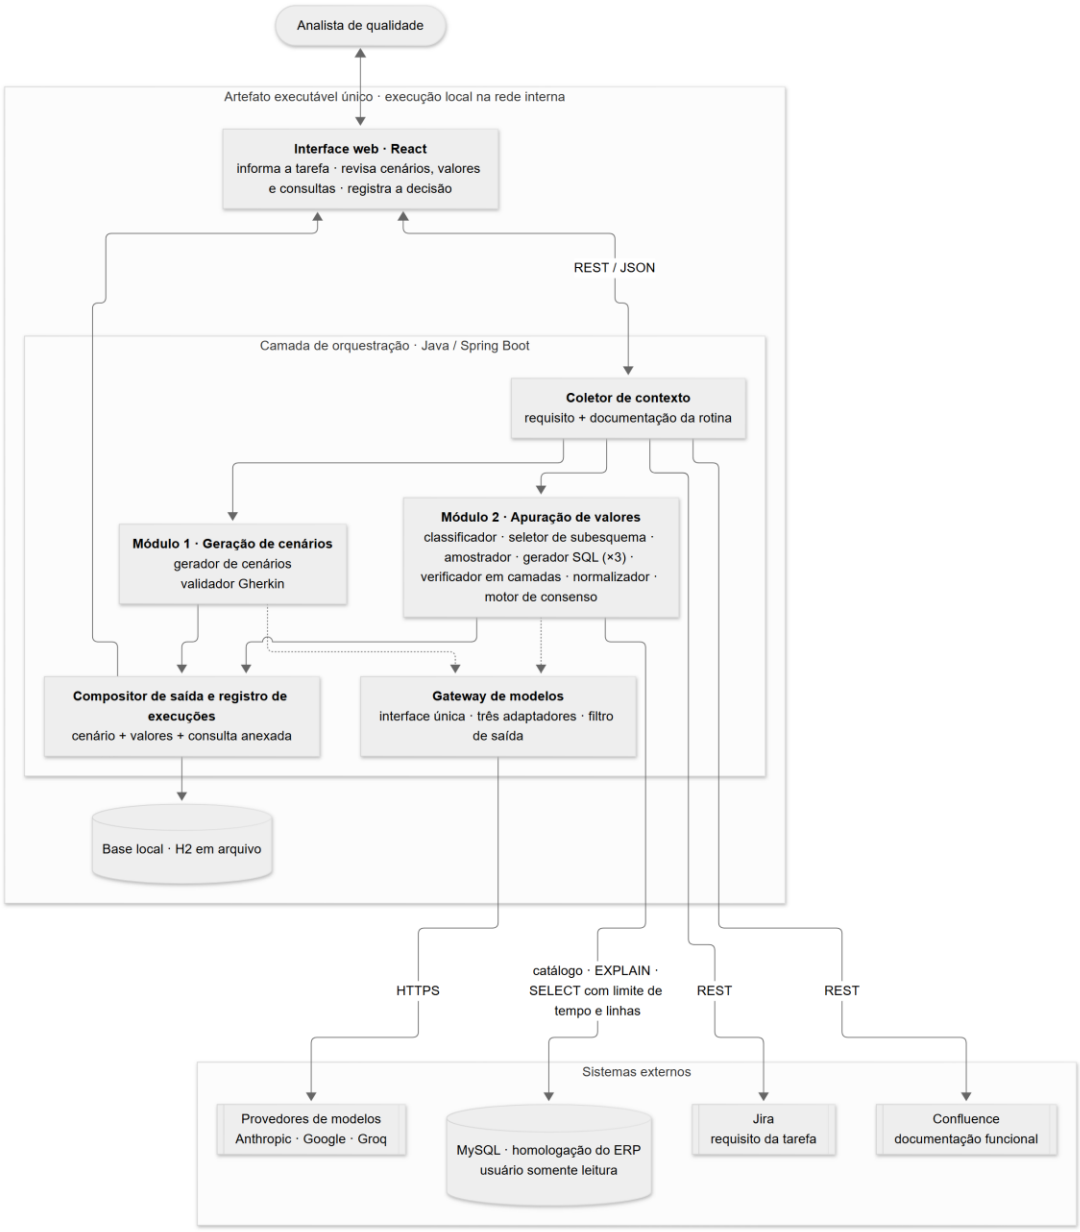


Fonte: elaborado pelo autor (2026).

2 Arquitetura da solução

A plataforma é um monólito modular empacotado em um único executável e executado localmente na rede interna, como definido na proposta. A escolha descarta deliberadamente uma arquitetura distribuída: trata-se de um projeto de uma pessoa, com prazo de um semestre, e a única exigência que pediria separação física, manter credenciais e banco fora do navegador, é atendida pela própria execução local. A Figura 2 apresenta os componentes e a forma como se comunicam.

Figura 2 – Arquitetura da plataforma



Fonte: elaborado pelo autor (2026).

A **interface web** é o único ponto de contato do analista: recebe a chave da tarefa, apresenta os cenários com os valores apurados e as consultas que os originaram, e registra a decisão de conferência. Comunica-se com a camada de orquestração por REST/JSON, servida pelo mesmo processo.

Na **camada de orquestração**, o **coletor de contexto** obtém o requisito no Jira e a documentação da rotina no Confluence, e entrega esse contexto aos dois módulos. O

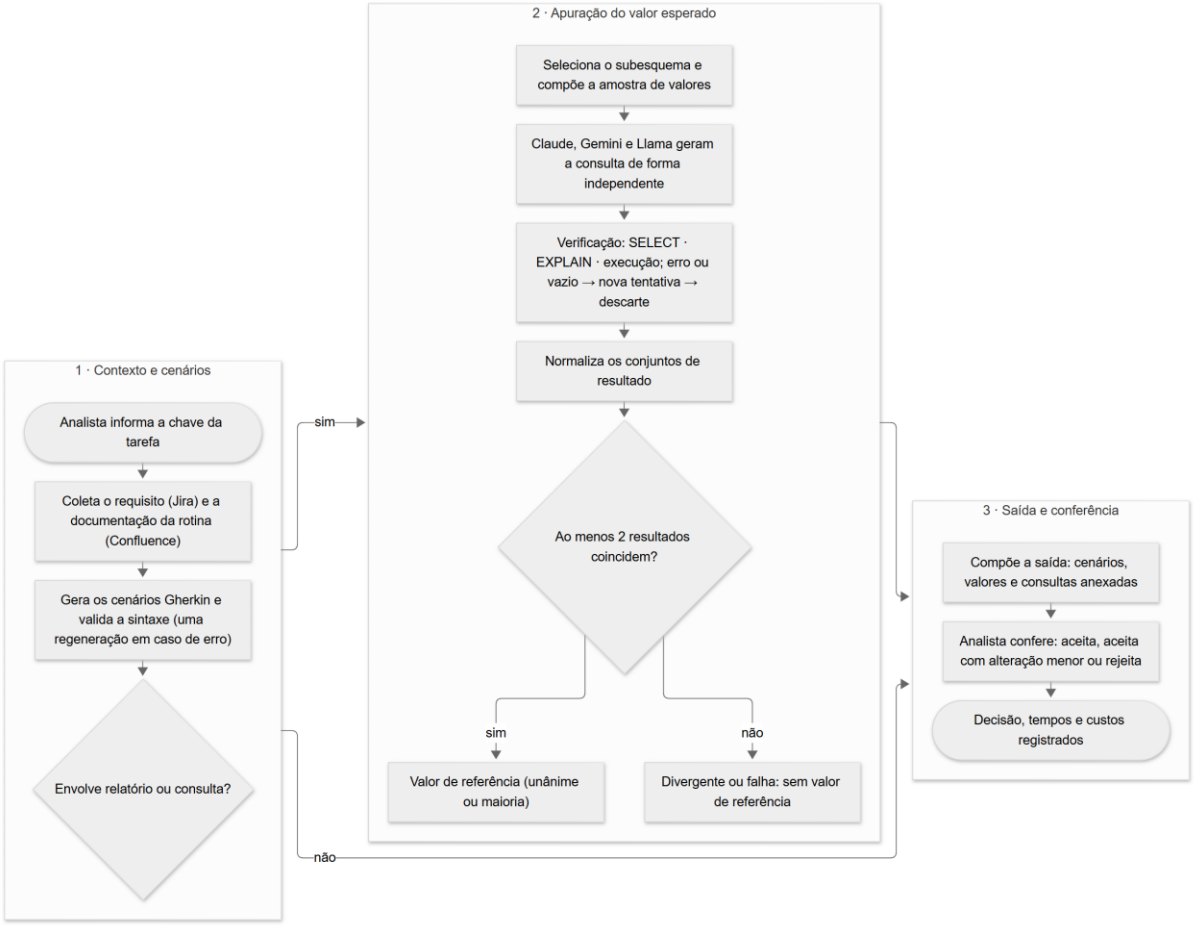
Módulo 1 redige os cenários e os submete ao validador Gherkin. O **Módulo 2** é acionado apenas quando o requisito envolve relatório ou consulta e encadeia as etapas descritas na proposta, da classificação do requisito ao motor de consenso. Ambos os módulos acessam os modelos exclusivamente pelo **gateway de modelos**, que oferece uma interface única com um adaptador por provedor; com isso, trocar a versão ou o provedor de um modelo não altera os módulos, e tokens, custo e latência são registrados em um único ponto. O gateway abriga também o filtro de saída descrito na seção 4, de modo que nenhum conteúdo chega a um provedor sem passar por ele. O **compositor de saída** reúne cenário, valores e consultas, e o **registro de execuções** grava tudo na base local, que alimenta a auditoria e as métricas da avaliação.

A base de homologação do ERP é acessada apenas pelo Módulo 2, com usuário de permissão exclusiva de leitura e limites de tempo e de linhas em toda consulta. A plataforma nunca escreve nessa base: seus próprios dados ficam na base local, separada.

3 Fluxo principal

A Figura 3 mostra o caminho de uma tarefa da entrada à conferência, em três etapas. A etapa 2 só é percorrida quando o classificador conclui que o requisito exige apuração de valores no banco.

Figura 3 – Fluxo principal de uma tarefa



Fonte: elaborado pelo autor (2026).

Cada candidato a consulta atravessa três camadas sucessivas: a análise sintática, que admite uma única instrução do tipo SELECT; o plano de execução, obtido por EXPLAIN; e a execução propriamente dita. Um candidato com erro ou com retorno vazio recebe uma nova tentativa, na qual a mensagem de erro é devolvida ao modelo; persistindo a falha, é descartado. Os candidatos válidos têm o conjunto de resultado normalizado segundo regras explícitas, para que diferenças de forma não sejam confundidas com diferenças de conteúdo:

– nomes e ordem das colunas são desconsiderados, pois cada modelo escolhe seus próprios apelidos;
– a ordem das linhas é desconsiderada, salvo quando o requisito especifica ordenação;

– valores numéricos são arredondados à escala da coluna de origem ou, na ausência dela, a duas casas;
– nulos recebem marcador próprio, distinto de texto vazio, e datas são escritas no formato ISO 8601;
– o conjunto normalizado é resumido por um *hash*, e dois candidatos concordam quando os *hashes* coincidem.

A decisão de consenso classifica cada apuração em um de quatro desfechos, descritos no Quadro 1.

Quadro 1 – Desfechos da decisão por consenso

Desfecho	Condição	Saída entregue ao analista
Unânime	Três candidatos válidos com o mesmo resultado	Valor de referência, com indicação de confiança alta
Maioria	Dois resultados coincidentes; o terceiro diverge ou foi descartado	Valor de referência, com indicação de confiança moderada e a consulta divergente exibida
Divergente	Dois ou mais candidatos válidos, sem resultados coincidentes	Nenhum valor de referência; as consultas são exibidas para apuração pelo analista
Falha	Menos de dois candidatos válidos após a nova tentativa	Nenhum valor de referência; os erros de cada modelo são registrados

Fonte: elaborado pelo autor (2026).

Em todos os desfechos a conferência humana é obrigatória. A plataforma entrega um valor **apurado**, obtido do banco, rastreável e reprodutível; ele só se torna **validado**, isto é, representativo da regra de negócio, depois da conferência do analista. O consenso não aprova o valor: indica o grau de confiança associado a ele, e a consulta anexada permite verificar sua origem sem reconstruí-la.

4 Dados enviados aos provedores e minimização

O acesso ao banco é somente leitura, mas parte do conteúdo da empresa precisa sair dela para que os modelos funcionem. O Quadro 2 inventaria o que é enviado em cada etapa e a medida aplicada. O princípio é enviar o mínimo necessário à tarefa e nunca enviar resultados de consultas: a normalização e o consenso ocorrem inteiramente dentro da plataforma.

Quadro 2 – Inventário do conteúdo enviado aos provedores de modelos

Etapa	O que é enviado	O que pode conter	Medida aplicada
Geração de cenários e classificação	Texto do requisito e da documentação da rotina	Nomes de clientes, documentos, e-mails ou telefones usados como	Pseudonimização pelo filtro de saída; documentação restrita à página da rotina

Etapa	O que é enviado	O que pode conter	Medida aplicada
		exemplo; informação interna	
Seleção de esquema e geração de SQL	Nomes de tabelas, colunas, tipos e chaves do subconjunto pertinente	Metadados confidenciais, sem dados pessoais	Envio apenas do subesquema; coberto pela autorização da empresa
Composição de amostra	Valores distintos de colunas de baixa cardinalidade e limites de datas	Dados reais da base	Somente colunas da lista de permitidas; texto livre nunca é amostrado
Nova tentativa	Consulta anterior e mensagem de erro do banco	Valores citados na mensagem de erro	Mensagem passa pelo filtro de saída
Normalização e consenso	Nada	—	Resultados das consultas nunca saem da plataforma

Fonte: elaborado pelo autor (2026).

As medidas combinam três técnicas, aplicadas em pontos definidos do fluxo:

– **lista de colunas permitidas**, no amostrador: só são amostradas colunas explicitamente aprovadas, como situação, tipo de movimento e unidade, revisadas com o responsável pela base; uma coluna nova fica de fora até ser avaliada, o que é mais seguro do que uma lista de bloqueio;

– **pseudonimização**, no filtro de saída do gateway: CPF, CNPJ, e-mail, telefone e nomes de pessoas cadastradas são substituídos por marcadores consistentes, como `<CPF_1>`, antes do envio, e a tabela de correspondência permanece apenas na base local;

– **supressão**: resultados de consultas, valores fora da lista de permitidas e campos de texto livre nunca são enviados.

Cada envio é registrado na base local com o conteúdo efetivamente transmitido, o que permite auditar o que saiu da empresa. A configuração adotada em cada provedor, conferida nos termos vigentes em 12/10/2026, é declarada no Quadro 3.

Quadro 3 – Configuração adotada em cada provedor

Provedor	Modalidade adotada	Uso dos dados para treinamento	Retenção declarada
Anthropic (Claude)	API comercial, com chave da organização	Não usa entradas e saídas para treinar modelos, salvo permissão expressa	Exclusão automática em até 30 dias; até 2 anos em caso de violação da política de uso
Google (Gemini)	API em nível pago, com faturamento ativo; o nível gratuito não é usado	No nível pago, não usa as entradas e saídas para melhorar produtos; no gratuito, usa e admite revisão humana	Registro por período limitado, apenas para detectar abuso; registro opcional de chamadas mantido desativado
Groq (Llama)	API do GroqCloud, com retenção zero ativada	Vedado pelo contrato, salvo permissão do cliente	Nenhuma com retenção zero; sem ela, até 30 dias para confiabilidade e abuso

Fonte: elaborado pelo autor com base em Anthropic (2026), Google (2026) e Groq (2026).

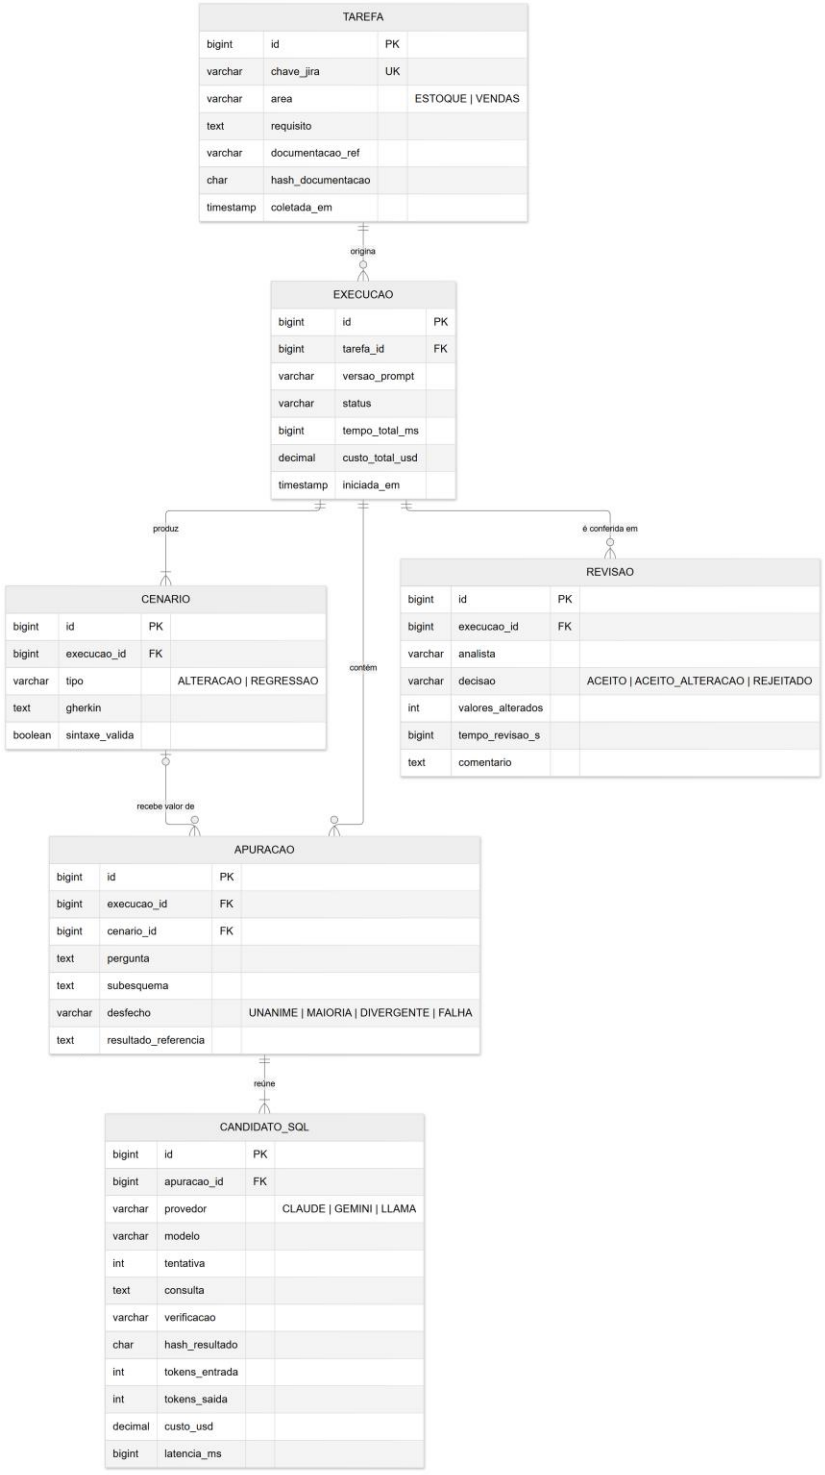
Duas decisões decorrem do quadro. O nível gratuito do Gemini fica vedado, porque nele o conteúdo pode ser lido por revisores humanos e usado para melhorar produtos; e a retenção zero é ativada no Groq, único provedor que a oferece ao próprio cliente. Nos demais casos, a retenção de até 30 dias recai sobre conteúdo já minimizado e pseudonimizado.

A empresa autorizou o uso do ambiente de homologação, das tarefas e da documentação, com a condição de que nenhuma informação sensível seja exposta. As medidas desta seção são a forma de cumprir essa condição.

5 Modelagem de dados

O esquema do ERP, com cerca de 125 tabelas, é apenas lido e não faz parte da modelagem. O que se modela são os dados da própria plataforma, restritos ao necessário para auditar cada execução e calcular as métricas da avaliação. A Figura 4 apresenta as seis entidades.

Figura 4 – Modelo entidade-relacionamento da base local



Fonte: elaborado pelo autor (2026).

Quadro 4 – Entidades da base local e métricas que alimentam

Entidade	**Papel**	**Métricas que alimenta**
TAREFA	Retrato do requisito e da referência à	Identificação do conjunto de

Entidade	Papel	Métricas que alimenta
	documentação no momento da coleta	avaliação
EXECUCAO	Uma passagem da plataforma sobre uma tarefa, com versão do prompt, tempo e custo totais	Custo e tempo por tarefa
CENARIO	Cada cenário gerado, marcado como de alteração ou de regressão	Cobertura e completude
APURACAO	Cada valor a apurar, com o subesquema usado, o desfecho e o resultado de referência	Concordância, acurácia, falso acordo e divergência
CANDIDATO_SQL	Cada consulta gerada por um modelo, com a verificação, o *hash* do resultado, os tokens e a latência	Acurácia por modelo, custo e tempo por consulta
REVISAO	A conferência do analista: decisão, valores alterados e tempo gasto	Aceitação e proporção de valores alterados

Fonte: elaborado pelo autor (2026).

A coluna `hash_documentacao` em TAREFA registra qual versão da documentação foi usada, já que as páginas do Confluence mudam com o tempo; sem ela, um experimento não poderia ser repetido com a mesma entrada.

6 Stack definida e justificada

Quadro 5 – Stack da plataforma

Tecnologia	Função e justificativa
Java 21 e Spring Boot 3	Camada de orquestração. Acesso maduro a bancos relacionais por JDBC, execução concorrente das três chamadas aos modelos e empacotamento em um único JAR executável. Java 21 é a versão de suporte estendido corrente.
Spring AI	Cliente dos modelos. Oferece abstração comum para Anthropic, Google e provedores compatíveis com a interface da OpenAI, caso da Groq, o que reduz cada adaptador do gateway a configuração. Se alguma limitação surgir, o adaptador afetado passa a usar o cliente HTTP do próprio provedor, sem impacto nos módulos.
React com TypeScript e Vite	Interface. O resultado do *build* é copiado para os recursos estáticos do Spring Boot e servido pelo mesmo processo, preservando o artefato único.
H2 em arquivo	Base local da plataforma. Não exige servidor, roda dentro do processo e mantém os dados da plataforma fisicamente separados da base do ERP.
MySQL Connector/J	Acesso à homologação com usuário somente leitura. O limite de tempo é aplicado pela dica `MAX_EXECUTION_TIME` e o de linhas pelo próprio *driver*.
JSqlParser	Primeira camada do verificador. Rejeita qualquer texto que não seja uma única instrução SELECT, inclusive múltiplas instruções e cláusulas de bloqueio, antes que a consulta chegue ao banco.
Analisador Gherkin do Cucumber	Validador do Módulo 1. É o mesmo analisador usado pelas ferramentas de BDD, o que torna a métrica de validade sintática comparável à reportada na literatura.
APIs REST do Jira e do Confluence	Coleta de contexto, com *token* de acesso do autor e apenas operações de leitura no MVP.
Git, GitHub e Mermaid	Versionamento do código e dos diagramas como texto. Os diagramas deste documento são gerados a partir dos arquivos .mmd do repositório.

Fonte: elaborado pelo autor (2026).

As versões exatas dos três modelos serão fixadas antes dos experimentos e registradas em cada execução, na coluna `modelo` de CANDIDATO_SQL, para que mudanças de versão pelo provedor não contaminem a comparação.

7 Backlog priorizado

O Quadro 6 lista os itens em ordem de prioridade. Nenhum item passa de oito horas, e cada um está associado ao marco em que deve estar pronto. Os itens da fatia vertical estão marcados com ●. O MVP soma 125 horas e os itens desejáveis, 22 horas.

Quadro 6 – Backlog priorizado

ID	Item	h	Prioridade	Marco	FV
B01	Esqueleto Spring Boot + React no mesmo build, gerando um único executável	4	MVP	E6	●
B02	Configuração de credenciais por variáveis de ambiente e perfil local	1	MVP	E6	●
B03	Base local H2 com migração das seis tabelas da plataforma	3	MVP	E6	●
B04	Cliente do Jira: obter o requisito pela chave da tarefa	3	MVP	E6	●
B05	Gateway de modelos com adaptador do Claude e registro de tokens, custo e latência	4	MVP	E6	●
B06	Conexão MySQL somente leitura com limite de tempo e de linhas	2	MVP	E6	●
B07	Verificador, camada 1: análise sintática que admite apenas SELECT	3	MVP	E6	●
B08	Geração de cenário Gherkin a partir do requisito (um modelo)	4	MVP	E6	●
B09	Geração de SQL por um modelo, com o esquema da área informado integralmente	4	MVP	E6	●
B10	Compositor: cenário com valor preenchido e consulta anexada	2	MVP	E6	●
B11	Tela: informar a tarefa e visualizar o resultado	4	MVP	E6	●
B12	Adaptadores do Gemini e do Llama (Groq) no gateway	4	MVP	E7	
B13	Geração paralela pelos três modelos e nova tentativa com a mensagem de erro	6	MVP	E7	
B14	Verificador, camadas 2 e 3: EXPLAIN e execução; descarte de erro e de vazio	4	MVP	E7	
B15	Normalizador: ordenação, arredondamento, nulos e datas	6	MVP	E7	
B16	Motor de consenso e classificação do desfecho	4	MVP	E7	
B17	Extração do esquema pelo INFORMATION_SCHEMA e grafo de chaves estrangeiras	6	MVP	E7	
B18	Amostrador de valores restrito à lista de colunas permitidas	5	MVP	E7	
B19	Filtro de saída no gateway: pseudonimização de dados pessoais no requisito, na documentação e nas mensagens de erro	5	MVP	E7	
B20	Cliente do Confluence: obter a página da rotina e convertê-la em texto	6	MVP	E8	
B21	Documentação funcional no prompt, com cenários de regressão	6	MVP	E8	
B22	Validação com o analisador Gherkin e uma regeneração em caso de erro	4	MVP	E8	
B23	Classificador: o requisito exige apuração de valores?	4	MVP	E8	
B24	Restrições de domínio obrigatórias no prompt (empresa, filial, cancelados, exclusão lógica)	4	MVP	E8	

ID	Item	h	Prioridade	Marco	FV
B25	Seleção do subesquema por similaridade de termos e expansão pelos relacionamentos	8	MVP	TCC II	
B26	Tela de revisão: aceitar, aceitar com alteração ou rejeitar, com registro de tempo	6	MVP	TCC II	
B27	Exibição do desfecho e da consulta de cada modelo	4	MVP	TCC II	
B28	Execução em lote sobre o conjunto de referência	6	MVP	TCC II	
B29	Exportação das métricas em CSV	3	MVP	TCC II	
B30	Registro dos cenários aprovados de volta na tarefa do Jira	6	Desejável	—	
B31	Cache do esquema e das amostras entre execuções	4	Desejável	—	
B32	Painel de custos por provedor	4	Desejável	—	
B33	Incorporação das alterações de código vinculadas à tarefa	8	Desejável	Futuro	

Fonte: elaborado pelo autor (2026).

7.1 Fatia vertical

A fatia vertical, itens B01 a B11, é o menor caminho que atravessa todas as camadas e prova a ideia central: o analista informa a chave de uma tarefa de relatório; a plataforma lê o requisito no Jira, gera o cenário e a consulta com um único modelo, recebendo o esquema da área integralmente, aceita apenas SELECT, executa a consulta em modo somente leitura e devolve o cenário com o valor preenchido e a consulta anexada, gravando a execução na base local. Soma 34 horas e é o conteúdo da E6. O consenso entre os três modelos, que é o diferencial do trabalho, entra logo em seguida, na E7, sobre essa mesma fatia.

7.2 Capacidade e risco de prazo

Até a banca de validação, os marcos E6, E7 e E8 somam 98 horas de implementação (34, 40 e 24 horas, respectivamente), acima das cerca de 74 horas previstas no cronograma das entregas para o mesmo período. A ordem do backlog foi construída para que o excesso recaia sobre o final: se for preciso cortar, a banca recebe a fatia vertical com consenso funcionando e o Módulo 1 sem a documentação funcional, e os itens restantes passam ao início do TCC II, junto das 27 horas já previstos ali para preparar o experimento. A seleção do subesquema (B25) foi deixada para o TCC II porque a fatia funciona enviando o esquema inteiro da área, o que a proposta admite como viável; o custo dessa simplificação será medido.

8 Repositório

O repositório foi criado com README descrevendo o projeto, os diagramas em Mermaid e o backlog em Markdown, gerado da mesma fonte que o Quadro 6. Ainda não há código: o primeiro *commit* de implementação será o esqueleto do item B01.

```
PlataformaTestes/
├── README.md
├── .gitignore
└── docs/
    ├── backlog.md
    └── diagramas/
        ├── contexto.mmd      contexto.svg      contexto.png
        ├── arquitetura.mmd   arquitetura.svg   arquitetura.png
        ├── fluxo.mmd         fluxo.svg         fluxo.png
        └── der.mmd           der.svg           der.png
```

Endereço: https://github.com/edukrause/PlataformaTestes

Referências

ANTHROPIC. **How long do you store my organization's data?** 2026. Disponível em: https://privacy.claude.com/en/articles/7996866-how-long-do-you-store-my-organization-s-data. Acesso em: 12 out. 2026.

ANTHROPIC. **Is my data used for model training?** 2026. Disponível em: https://privacy.claude.com/en/articles/7996868-is-my-data-used-for-model-training. Acesso em: 12 out. 2026.

GOOGLE. **Gemini API Additional Terms of Service**. 2026. Disponível em: https://ai.google.dev/gemini-api/terms. Acesso em: 12 out. 2026.

GROQ. **Your Data in GroqCloud**. 2026. Disponível em: https://console.groq.com/docs/your-data. Acesso em: 12 out. 2026.

Observações sobre esta entrega

1. **Ajustes da avaliação da proposta.** A seção 1 atende ao pedido de Douglas Bianchezzi sobre a estrutura do ERP, e a seção 4 aos de Rafael Rodrigues Barbosa e Anderson Luiz Fernandes sobre minimização e anonimização dos dados. O item B19 do backlog implementa o filtro de saída.
2. **Autorização da empresa.** Concedida pela gestão, com a condição de não expor informação sensível, atendida pelas medidas da seção 4.
3. **Prazo.** Esta entrega e a E3 foram enviadas depois das datas previstas. O backlog e a seção 7.2 já consideram o calendário real até a banca.

E5 — PLANO DE VALIDAÇÃO

Eduardo Krause (RA 12520157) — Análise e Desenvolvimento de Sistemas — UNIMATER
Orientador: Prof. Me. João Mazzochin — Entrega de 13/10/2026

Este documento define como o trabalho será provado antes que a plataforma exista: métricas, linhas de base, protocolo do experimento e instrumentos de coleta. Cada objetivo específico da proposta está amarrado a pelo menos uma métrica, e cada métrica tem unidade, forma de coleta e valor esperado definidos de antemão. Incorpora os pontos 1, 3, 4, 5 e 6 da avaliação da proposta: a distinção entre valor apurado e validado, os critérios de inclusão fixados antes da coleta, a rubrica de aceitação, o teste de significância do tempo e as limitações de generalização. O conteúdo corresponde à subseção 3.4 do artigo.

1 Tipo de validação

Em coerência com a Design Science Research adotada na proposta, a avaliação verifica se o artefato resolve o problema para o qual foi construído, no ambiente em que será usado (HEVNER et al., 2004; PEFFERS et al., 2007). Combina três formas de validação: **experimento com métricas técnicas**, para o Módulo 2, em que os valores apurados são confrontados com consultas de referência; **avaliação por especialistas**, para o Módulo 1, em que quatro analistas de qualidade da equipe, excluído o autor, julgam os cenários gerados; e **comparação pareada com o processo atual**, em que o tempo de elaboração do caso de teste é medido com e sem a plataforma sobre as mesmas tarefas.

Uma distinção orienta as métricas do Módulo 2. A execução no banco garante que o valor é **apurado**: existe nos dados, é rastreável e reprodutível. Não garante que seja **validado**, isto é, que a consulta represente a regra de negócio. A avaliação mede essa distância diretamente: a acurácia (M9) compara o valor consensuado com uma consulta de referência conferida no próprio relatório do sistema, e a taxa de falso acordo (M11) conta os casos em que os modelos concordam em uma consulta que não representa a regra.

2 Objetivos específicos e métricas

O Quadro 1 associa cada objetivo específico às métricas que o verificam, definidas no Quadro 2.

Quadro 1 – Objetivos específicos e métricas associadas

Objetivo específico	Métricas	Pergunta que a métrica responde
OE1 — Caracterizar o processo atual de elaboração de casos de teste	M1, M2 (procedimento atual)	Com que frequência a apuração de valores aparece, e quanto tempo o procedimento atual consome?
OE2 — Implementar a geração de cenários a partir do requisito e da documentação	M3, M7	Os cenários são válidos, e a documentação funcional amplia a cobertura dos comportamentos da rotina?
OE3 — Implementar a apuração por múltiplos modelos com decisão por consenso	M8, M10, M13	Os modelos concordam, quanto cada um acerta isoladamente, e a que custo?
OE4 — Avaliar a qualidade dos cenários e a acurácia dos valores	M2, M4, M5, M6, M9, M11, M12	Os cenários são aceitos, os valores consensuados estão corretos, e quando o consenso engana?

Fonte: elaborado pelo autor (2026).

3 Métricas

Os valores esperados do Quadro 2 são hipóteses fixadas antes da coleta. Onde a literatura oferece referência, ela é indicada; os demais serão revistos apenas com base no teste-piloto, nunca após os resultados do experimento.

Quadro 2 – Métricas da avaliação

ID	Métrica	O que mede	Como é coletada	Unidade	Valor esperado
M1	Incidência de apuração	Proporção das tarefas do acervo que exigem valor esperado obtido no banco	Classificação manual de amostra aleatória de 100 tarefas do acervo	%	Descritiva (caracterização)
M2	Tempo de elaboração	Tempo para produzir o caso de teste pronto para execução, no procedimento atual e com a plataforma	Cronometragem por sessão, registrada na planilha do Apêndice B	min por tarefa	Redução mediana ≥ 30%, significativa a 5%
M3	Validade sintática	Proporção de arquivos de cenários aceitos pelo analisador Gherkin na primeira geração	Automática, pelo registro de execuções	%	≥ 90% (93,3% em Fonseca, Lima e Faria, 2025)
M4	Aceitação dos cenários	Distribuição das decisões: aceito sem alteração, aceito com alteração menor, rejeitado	Ficha de avaliação (Apêndice A) com a rubrica do Quadro 4, dois analistas por tarefa	% de tarefas	≥ 60% aceitas, com ou sem alteração (68% em Ferreira et al., 2025)
M5	Qualidade percebida	Clareza, testabilidade, concisão e valor dos cenários (OLIVEIRA; MARCZAK; MORALLES, 2019)	Ficha de avaliação, escala de 1 a 5 por atributo	média (1–5)	≥ 4,0 em cada atributo
M6	Cobertura do caso de referência	Proporção dos itens verificados no caso do analista que os cenários gerados também verificam; e itens adicionais válidos	Ficha de avaliação, item a item	% e contagem	≥ 70% de cobertura
M7	Completude frente à documentação	Proporção dos comportamentos documentados da rotina cobertos pelos cenários	Lista de comportamentos preparada antes da geração; comparação com e sem documentação	%	Superior à versão sem documentação
M8	Concordância	Distribuição dos desfechos:	Automática, pelo registro	% de	Divergente + falha ≤

ID	Métrica	O que mede	Como é coletada	Unidade	Valor esperado
	entre modelos	unânime, maioria, divergente e falha	de execuções	apurações	25%
M9	Acurácia do consenso	Proporção das apurações com valor de referência cujo resultado coincide com o da consulta de referência	Comparação dos conjuntos normalizados	%	≥ 80% e superior a M10
M10	Acurácia individual	A mesma medida, para cada modelo isolado	Comparação dos conjuntos normalizados	% por modelo	Linha de base de M9
M11	Falso acordo	Proporção das apurações com consenso em que o resultado consensuado diverge da referência	Comparação dos conjuntos normalizados	%	≤ 10%
M12	Valores alterados na conferência	Proporção dos valores apurados que o analista corrige antes de executar o teste	Tela de revisão (REVISAO.valores_alterados)	%	≤ 10%
M13	Custo e tempo por apuração	Custo em tokens dos três modelos, convertido pela tabela de preços vigente, e tempo total	Automática, pelo registro de execuções	US$ e s	≤ US$ 0,10 e ≤ 60 s

Fonte: elaborado pelo autor (2026).

4 Linhas de base

Cada comparação tem uma linha de base explícita, apresentada no Quadro 3. A mais importante é o **procedimento atual da equipe**, que já emprega ferramentas de propósito geral com fornecimento manual de contexto. Comparar com ele, e não com uma elaboração inteiramente manual, é a escolha mais exigente: a plataforma precisa superar o que a equipe já faz com apoio de modelos, e não um cenário que deixou de existir.

Quadro 3 – Linhas de base da avaliação

Linha de base	O que isola	Métricas
Procedimento atual da equipe, com ferramentas de propósito geral	O ganho de usar a plataforma no trabalho real	M2, M6
A própria plataforma sem a documentação funcional (ablação)	A contribuição da segunda fonte de contexto, diferencial do Módulo 1	M6, M7
Cada modelo isolado	O ganho do consenso sobre o melhor modelo sozinho	M9 × M10
Consulta de referência validada por analista	A correção do valor apurado	M9, M10, M11
Resultados publicados (FONSECA; LIMA; FARIA, 2025; FERREIRA et al., 2025)	Ordem de grandeza esperada; não há comparação direta	M3, M4

Fonte: elaborado pelo autor (2026).

5 Protocolo do experimento

O protocolo foi escrito para que outra pessoa, com acesso ao mesmo ambiente, consiga repeti-lo. Todos os dados brutos são registrados desde o teste-piloto: as execuções na base local da plataforma e as avaliações e tempos em planilha.

5.1 Preparação do ambiente

- Fixar as versões dos três modelos e a temperatura zero, onde o provedor permitir, e registrar ambas.
- Versionar os *prompts* no repositório; cada execução grava a versão usada.
- Executar todas as consultas, da plataforma e de referência, na mesma janela de tempo e com o mesmo usuário somente leitura. Ao final, reexecutar as consultas de referência: se algum resultado mudar, os dados foram atualizados durante o experimento e o caso é descartado e relatado.
- Registrar a tabela de preços de cada provedor na data da execução.

5.2 Conjunto 1: tarefas para o Módulo 1

Os critérios de seleção ficam fixados nesta data, antes de qualquer coleta, e são registrados no Apêndice E. O acervo é o projeto do sistema estudado na ferramenta de gestão de tarefas, e é elegível a tarefa que atende a todos os critérios de inclusão:

- **I1** — é do tipo melhoria, *bug* ou tarefa, está com situação Finalizada e foi concluída entre 01/01/2025 e 30/09/2026;
- **I2** — o campo que registra a rotina afetada, com o caminho de menu, cita a área de estoque ou a de vendas, mas não as duas, para que cada tarefa pertença a uma única área;
- **I3** — o campo Casos de teste, preenchido pelo analista, não está vazio;
- **I4** — o requisito tem descrição textual de ao menos 50 palavras, e não apenas título;
- **I5** — a rotina afetada possui página de documentação funcional revisada.

E é excluída a tarefa que se enquadra em qualquer critério de exclusão:

- **E1** — não tem comportamento funcional verificável, como ajustes de infraestrutura ou de desempenho;
- **E2** — duplica outra tarefa já selecionada;
- **E3** — teve o caso de referência elaborado pelo próprio autor, para que ele não avalie, ainda que indiretamente, o próprio trabalho.

Os critérios I1 a I3 são aplicados por consulta ao Jira sobre todo o acervo. Os demais exigem a leitura de cada tarefa e são aplicados às tarefas em ordem aleatória, definida por semente registrada, até se obterem 18 elegíveis por área: três para a calibração da rubrica e 15 para a avaliação. O relatório final informa o total disponível, quantas tarefas foram examinadas, quantas cada critério eliminou e quantas foram selecionadas, de modo a mostrar que a seleção não recaiu apenas sobre casos favoráveis. Antes de qualquer geração, o autor extrai da documentação de cada rotina a lista de comportamentos esperados, conferida por um analista, que serve de referência para M7.

5.3 Conjunto 2: perguntas para o Módulo 2

São considerados todos os relatórios e consultas das duas áreas, sem amostragem. Para cada um, formulam-se de uma a três perguntas de negócio, cada qual com a consulta SQL de referência. As consultas de referência são escritas pelo autor **antes** de qualquer execução da plataforma e conferidas por um analista, que executa a consulta e confirma o valor no próprio relatório do sistema.

5.4 Execução do Módulo 2

Cada pergunta é submetida uma vez à plataforma completa, que registra os três candidatos, as verificações, o desfecho e os custos. M8 a M11 e M13 são calculadas a partir desse registro, aplicando à consulta de referência a mesma normalização aplicada aos candidatos. Para medir a variação causada pela não determinação dos modelos (SALLOU; DURIEUX; PANICHELLA, 2024), um subconjunto de dez perguntas é executado três vezes, e relata-se quantos desfechos mudaram entre as repetições.

5.5 Avaliação dos cenários pelos analistas

Para cada tarefa, a plataforma gera duas versões: a completa e a sem documentação. Cada versão completa é avaliada por dois analistas, de forma independente, na ficha do Apêndice A; com 30 tarefas e quatro analistas, cada um avalia 15. A concordância entre os dois avaliadores de cada tarefa na decisão de M4 é medida pelo coeficiente kappa de Cohen, e as divergências são resolvidas em conversa entre eles, registrando-se a decisão final. Para M7, um terceiro analista

recebe as duas versões em ordem aleatória, identificadas apenas como A e B, e marca os comportamentos cobertos por cada uma.

Para que a aceitação não dependa da interpretação de cada analista, as três categorias de M4 seguem a rubrica do Quadro 4. O critério que separa as duas primeiras é a intenção do cenário: a alteração é menor quando o que é testado continua o mesmo.

Quadro 4 – Rubrica de aceitação dos cenários

Categoria	Critério	Exemplos
Aceito sem alteração	O analista executaria os cenários como estão	Nenhuma mudança
Aceito com alteração menor	Ajustes que não mudam o que é testado: nenhum cenário incluído ou removido e nenhum passo Então com resultado esperado diferente	Corrigir redação ou ortografia; renomear um passo; trocar o código de produto do exemplo por outro equivalente; reordenar cenários
Rejeitado	Mudança no que é testado, ou defeito que impede a execução	Incluir cenário para comportamento omitido; remover cenário fora do escopo; corrigir resultado esperado; passo ambíguo ou não executável (SOARES et al., 2023)

Fonte: elaborado pelo autor (2026).

Antes da avaliação, os quatro analistas aplicam a rubrica a uma mesma amostra de seis tarefas, e a concordância entre eles é medida pelo kappa de Fleiss. Valor abaixo de 0,60 indica que a rubrica ainda admite leituras diferentes: as divergências são discutidas, os exemplos do Quadro 4 são ampliados e a calibração é repetida com outras seis tarefas antes de seguir. As tarefas de calibração não entram no cálculo das métricas.

5.6 Comparação pareada de tempo

As 30 tarefas do Conjunto 1 são preparadas duas vezes: uma pelo procedimento atual e outra com a plataforma, incluindo a conferência dos cenários e valores. Para evitar que o ganho da repetição seja atribuído à plataforma, as duas preparações de uma mesma tarefa são feitas por analistas diferentes, e nenhum analista prepara tarefa cujo caso original tenha elaborado. A atribuição é balanceada: cada analista faz 15 sessões, sete ou oito em cada condição, alternando a ordem das condições entre os analistas. O tempo começa quando a tarefa é aberta e termina quando o caso de teste está pronto para execução.

A diferença de tempo é calculada por tarefa. Se as diferenças tiverem distribuição normal pelo teste de Shapiro-Wilk, aplica-se o teste *t* pareado, com o tamanho do efeito pelo *d* de Cohen para dados pareados; caso contrário, o teste de postos sinalizados de Wilcoxon, com o tamanho do efeito pela correlação bisserial de postos. A diferença é considerada significativa com $p < 0,05$, e relatam-se a mediana das diferenças e seu intervalo de confiança de 95%. Se a disponibilidade dos analistas não permitir as 60 sessões, a medição é reduzida a 12 tarefas sorteadas, mantendo o desenho, e a redução é relatada como limitação.

5.7 Participantes e cuidados éticos

Participam quatro analistas de qualidade da equipe, convidados individualmente, com participação voluntária e em horário de trabalho autorizado pela gestão. Cada um assina o termo de consentimento do Apêndice C e é identificado nos dados apenas por código (A1 a A4). O autor conduz as sessões, mas não avalia cenários nem tem seus casos incluídos no conjunto de referência. Nenhum dado pessoal da base é enviado aos modelos: as colunas com esse tipo de dado ficam em lista de bloqueio do amostrador.

5.8 Análise dos dados

Todas as métricas são apresentadas por estatística descritiva, com mediana e intervalo interquartil para tempos e custos. Além do teste de M2 (seção 5.6) e dos coeficientes kappa de M4, a comparação entre M9 e o melhor resultado de M10 usa o teste de McNemar sobre as mesmas perguntas, desde que haja ao menos 20 perguntas com consenso; abaixo disso, a comparação é apenas descritiva. Os dados brutos são publicados em forma anonimizada no repositório.

6 Ameaças à validade e limitações

Quadro 5 – Ameaças à validade e tratamentos

Ameaça	Tratamento
O autor integra a equipe e construiu a plataforma	Avaliação feita apenas pelos outros quatro analistas; casos do autor excluídos (E3); consultas de referência escritas antes das execuções
Conjunto de referência elaborado com apoio de ferramentas de propósito geral	Declarado como representativo do procedimento atual, e não como referência isenta de assistência

Ameaça	Tratamento
Aprendizado entre sessões na comparação de tempo	Cada analista nunca repete uma tarefa; atribuição cruzada entre as condições
Julgamento subjetivo da aceitação	Definição operacional das categorias, dois avaliadores por tarefa e kappa relatado
Falso positivo na comparação por execução	Medido diretamente por M11; normalização documentada
Mudança de versão ou de comportamento dos modelos	Versões fixadas e registradas; repetição de dez perguntas
Generalização limitada	Duas áreas de um único sistema, que compartilham parte do esquema; registrado como limitação

Fonte: elaborado pelo autor (2026).

A limitação de maior consequência é a generalização. Estoque e vendas compartilham parte do modelo de dados, de modo que as perguntas do Conjunto 2 percorrem tabelas e junções semelhantes. Os resultados permitem afirmar como a plataforma se comporta nessas duas áreas, desse sistema, com essa equipe. Não permitem afirmar o mesmo desempenho em áreas com regras de natureza diferente, como a fiscal e a contábil citadas na justificativa, em outros ERPs ou com analistas de outras equipes. Essas extrapolações serão tratadas como hipóteses para trabalhos futuros, e não como conclusões.

7 Cronograma da validação

Quadro 6 – Cronograma da validação

Período	Atividade
até 20/10/2026	Teste-piloto do protocolo (seção 8) e revisão das instruções
até 10/11/2026	Seleção do Conjunto 1, listas de comportamentos e consultas de referência do Conjunto 2, em paralelo ao desenvolvimento
11/11 a 17/11/2026	Execução do Módulo 2 sobre o Conjunto 2 e primeira rodada de avaliação, como resultado preliminar para a banca
fevereiro e março de 2027	Experimento completo: avaliação dos 30 cenários, comparação pareada de tempo e análise

Fonte: elaborado pelo autor (2026).

Os conjuntos de referência não dependem da plataforma e são montados enquanto ela é desenvolvida. Assim, se a implementação atrasar, a banca de validação ainda recebe o protocolo executado sobre o que estiver pronto, com dados reais, e não apenas a sua descrição.

8 Teste-piloto do protocolo

Como a plataforma ainda não existe, o piloto simula o protocolo manualmente, com o próprio autor no papel de analista, para descobrir instruções ambíguas e estimar a duração das sessões. Usa duas tarefas, uma de cada área, e três perguntas de negócio:

1. aplicar os critérios I1 a I5 e E1 a E3 às duas tarefas e anotar qualquer critério difícil de decidir;
2. gerar os cenários colando requisito e documentação nas interfaces de conversa dos três modelos, com o rascunho do *prompt*, e preencher a ficha do Apêndice A cronometrando o tempo;
3. para cada pergunta, obter uma consulta de cada modelo, executá-la com o usuário somente leitura, aplicar à mão as regras de normalização e decidir o desfecho;
4. comparar com a consulta de referência escrita antes e registrar tudo no Apêndice D.

O piloto será executado até 20/10/2026. Seus resultados são registrados no Apêndice D e orientam a revisão das instruções antes da E6.

Referências

FERNANDES, H.; PERKUSICH, M.; ALBUQUERQUE, D.; SILVA, I.; SANTOS, D. F. S.; GORGÔNIO, K.; PERKUSICH, A. A Comparative Study of LLMs for Gherkin Generation. In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 39., 2025, Recife. **Anais** [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 171-181. DOI: 10.5753/sbes.2025.9888.

FERREIRA, M.; VIEGAS, L.; FARIA, J. P.; LIMA, B. Acceptance Test Generation with Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATION OF SOFTWARE TEST (AST), 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/AST66626.2025.00007.

FONSECA, P. L.; LIMA, B.; FARIA, J. P. Streamlining Acceptance Test Generation for Mobile Applications Through Large Language Models: An Industrial Case Study. In: IEEE/ACM INTERNATIONAL CONFERENCE ON AUTOMATED SOFTWARE ENGINEERING (ASE), 40., 2025. **Proceedings** [...]. IEEE, 2025. DOI: 10.1109/ASE63991.2025.00273.

HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. Design Science in Information Systems Research. **MIS Quarterly**, v. 28, n. 1, p. 75-105, 2004. DOI: 10.2307/25148625.

OLIVEIRA, G.; MARCZAK, S.; MORALLES, C. How to Evaluate BDD Scenarios' Quality? In: SIMPÓSIO BRASILEIRO DE ENGENHARIA DE SOFTWARE (SBES), 33., 2019, Salvador. **Anais** [...]. New York: ACM, 2019. p. 481-490. DOI: 10.1145/3350768.3351301.

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A Design Science Research Methodology for Information Systems Research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45-77, 2007. DOI: 10.2753/MIS0742-1222240302.

SALLOU, J.; DURIEUX, T.; PANICHELLA, A. Breaking the Silence: the Threats of Using LLMs in Software Engineering. In: INTERNATIONAL CONFERENCE ON SOFTWARE ENGINEERING: NEW IDEAS AND EMERGING RESULTS (ICSE-NIER), 46., 2024, Lisboa. **Proceedings** [...]. New York: ACM, 2024. p. 102-106. DOI: 10.1145/3639476.3639764.

SOARES, E.; ARANDA, M.; OLIVEIRA, N.; RIBEIRO, M.; GHEYI, R.; SOUZA, E.; MACHADO, I.; SANTOS, A.; FONSECA, B.; BONIFÁCIO, R. Manual Tests Do Smell! Cataloging and Identifying Natural Language Test Smells. In: ACM/IEEE INTERNATIONAL SYMPOSIUM ON EMPIRICAL SOFTWARE ENGINEERING AND MEASUREMENT (ESEM), 2023. **Proceedings** [...]. IEEE, 2023. p. 1-11.

Apêndice A — Ficha de avaliação de cenários

Avaliador: A__ Tarefa: _____ Data: ___/___/2026 Início: ___:___ Fim: ___:___

1. Decisão sobre o conjunto de cenários (marque uma)

- ( ) **Aceito sem alteração** — executaria como está.
- ( ) **Aceito com alteração menor** — só redação, nome de passo ou valor de exemplo; nenhum cenário incluído ou removido; nenhum resultado esperado alterado.
- ( ) **Rejeitado** — omite o comportamento central, tem resultado esperado incorreto ou defeito que impede a execução.

2. Atributos de qualidade (1 = discordo totalmente; 5 = concordo totalmente)

Quadro 7 – Escala de qualidade dos cenários

Atributo	Afirmação	1	2	3	4	5
Clareza	Os cenários são compreensíveis por quem não é técnico					
Testabilidade	Cada cenário pode ser executado como teste sem interpretação adicional					
Concisão	Não há ambiguidade nem redundância entre passos e cenários					
Valor	Os cenários verificam o que importa para o usuário da rotina					

Fonte: adaptado de Oliveira, Marczak e Moralles (2019).

3. Cobertura do caso de referência

Quadro 8 – Itens do caso de referência

Item verificado no caso do analista	Coberto pelos cenários gerados?
1.	( ) sim ( ) parcialmente ( ) não
2.	( ) sim ( ) parcialmente ( ) não
3.	( ) sim ( ) parcialmente ( ) não
…	

Fonte: elaborado pelo autor (2026).

Itens **adicionais** propostos pela plataforma que não estão no caso de referência: ____ válidos ____ inválidos.

Valores esperados corrigidos durante a conferência: ____ de ____. Observações: _____

Apêndice B — Registro de tempo da comparação pareada

Quadro 9 – Planilha de registro de tempo

Sessão	Analista	Tarefa	Condição	Início	Fim	Minutos	Observações
S01	A1		atual / plataforma				
S02	A2		atual / plataforma				
…							

Fonte: elaborado pelo autor (2026).

Regras: o tempo começa quando a tarefa é aberta e termina quando o caso de teste está pronto para execução. Interrupções acima de dois minutos são descontadas e anotadas. Nenhum analista prepara a mesma tarefa duas vezes, nem tarefa cujo caso original tenha elaborado.

Apêndice C — Termo de consentimento livre e esclarecido

Você está sendo convidado(a) a participar da avaliação do Trabalho de Conclusão de Curso *Plataforma para geração de cenários de teste em sistemas ERP assistida por modelos de linguagem, com valores esperados verificados em banco de dados*, de autoria de Eduardo Krause, acadêmico do curso de Análise e Desenvolvimento de Sistemas do Centro Universitário Mater Dei (UNIMATER), sob orientação do Prof. Me. João Mazzochin.

O que você fará. Avaliar cenários de teste gerados pela plataforma, em fichas padronizadas, e preparar casos de teste para tarefas já concluídas, com e sem a plataforma, com o tempo cronometrado. A participação estimada é de dez a doze horas, distribuídas em sessões durante o horário de trabalho, com autorização da gestão.

Riscos e cuidados. O risco é mínimo, limitado ao tempo dedicado e a eventual desconforto por ter o tempo medido. O objetivo é avaliar a plataforma, e não o seu desempenho: os resultados nunca serão usados para avaliação profissional, e você será identificado(a) apenas por código (A1 a A4).

Participação voluntária. Você pode recusar ou desistir a qualquer momento, sem qualquer prejuízo e sem precisar justificar. Os dados coletados serão usados exclusivamente neste trabalho e em publicações dele derivadas, sempre de forma anonimizada.

Contato do pesquisador: eduardokrause678@gmail.com. Contato do orientador: joaomazzochin@gmail.com.

Declaro que li e compreendi este termo e aceito participar.

Nome: _____

Assinatura: _____ Data: ___/___/2026

Apêndice D — Registro do teste-piloto

Quadro 10 – Registro do teste-piloto

Item	Resultado
Data de execução	
Tarefas usadas (área)	
Critérios de seleção difíceis de decidir	
Tempo para preencher a ficha do Apêndice A	
Desfechos das três perguntas (unânime, maioria, divergente, falha)	
Resultado consensuado igual ao de referência?	
Regras de normalização que precisaram de ajuste	
Instruções ambíguas encontradas	
Alterações feitas no protocolo	

Fonte: elaborado pelo autor (2026).

Apêndice E — Critérios de seleção registrados antes da coleta

Registrado em 13/10/2026, antes do exame individual de qualquer tarefa para fins de seleção. As contagens de I1 a I3 foram obtidas por consulta ao Jira em 12/10/2026.

Critérios de inclusão: I1 a I5. Critérios de exclusão: E1 a E3 (seção 5.2). Semente do sorteio: 20261030.

Os critérios são aplicados na ordem do quadro, e cada linha conta as tarefas eliminadas apenas por aquele critério. A partir de I4, as contagens referem-se às tarefas examinadas em ordem aleatória. Só são divulgadas contagens: as tarefas selecionadas são identificadas por código (T01 a T30), sem título, cliente ou conteúdo.

Quadro 11 – Funil de seleção das tarefas

Etapa	Estoque	Vendas	Total
Tarefas finalizadas no projeto no período (I1)	—	—	2.913
Rotina cita a área (I2)	276	592	781
(−) citam as duas áreas (I2)	87	87	87
(−) sem casos de teste preenchidos (I3)	0	0	0
Disponíveis após I1 a I3	189	505	694
Examinadas em ordem aleatória			
(−) requisito com menos de 50 palavras (I4)			
(−) rotina sem documentação revisada (I5)			
(−) sem comportamento funcional (E1)			
(−) duplicadas (E2)			
(−) caso de referência elaborado pelo autor (E3)			
Elegíveis obtidas	18	18	36
Calibração da rubrica	3	3	6
Selecionadas por sorteio	15	15	30

Fonte: elaborado pelo autor (2026).

AJUSTES SOLICITADOS NA AVALIAÇÃO DA PROPOSTA

Eduardo Krause (RA 12520157) — Análise e Desenvolvimento de Sistemas — UNIMATER
Orientador: Prof. Me. João Mazzochin — Entrega de 13/10/2026

Este documento responde ao retorno consolidado de 15/09/2026. O Quadro 1 lista cada ajuste pedido pela banca, quem o pediu e onde foi atendido nas entregas E3, E4 e E5. O Quadro 2 confere os ajustes do retorno de 23/08. A seção 3 traz a decisão pendente sobre o título, e a seção 4 explica como os ajustes chegam à versão final do TCC I.

1 Ajustes da banca

Quadro 1 – Ajustes solicitados e onde foram atendidos

#	Ajuste solicitado	Apontado por	Onde foi atendido	Situação
1	Conceito de “verificação” dos valores esperados	Rafael	E3, seção 2.1: distinção entre valor apurado e validado. E4, seção 3. E5, seção 1: M9 e M11 medem a distância entre os dois	Atendido; título em decisão (seção 3)
2	Segurança e minimização dos dados enviados aos provedores	Rafael, Anderson	E4, seção 4: inventário por etapa, lista de colunas permitidas, pseudonimização, supressão e termos de cada provedor (Gemini só no nível pago; Groq com retenção zero). Backlog B18 e B19	Atendido
3	Critérios de inclusão das tarefas definidos desde já	Anderson	E5, seção 5.2 (I1 a I5, E1 a E3) e Apêndice E, registrado em 13/10/2026 com o funil de seleção e as contagens reais do acervo	Atendido
4	Definição de “aceito com alteração menor”	Anderson	E5, seção 5.5: rubrica com exemplos (Quadro 4) e calibração dos quatro analistas pelo kappa de Fleiss	Atendido
5	Significância da diferença de tempo	Anderson	E5, seção 5.6: 30 tarefas pareadas, analistas diferentes por condição, t pareado ou Wilcoxon e tamanho do efeito	Atendido
6	Limite de generalização dos resultados	Anderson	E5, seção 6: o que os resultados permitem e não permitem afirmar	Atendido
7	Estrutura do ERP base	Douglas	E4, seção 1 e Figura 1: ERP web com banco MySQL e diagrama de contexto da plataforma em relação a ele	Atendido

Fonte: elaborado pelo autor (2026).

2 Ajustes de 23/08 conferidos

Quadro 2 – Conferência dos ajustes de 23/08

Ajuste	Conferência na proposta entregue
Cronograma na janela ago/2026 a jul/2027, com o marco do TCC I	Atendido: Quadro 2 da proposta
Referências da lista citadas no texto ou removidas	Atendido: Arredondo-Reyes, Karpurapu, Paduraru e Wynne e Hellesoy são citados na introdução

Ajuste	Conferência na proposta entregue
Família do modelo servido pela Groq identificada	Atendido: seção 5.4 identifica a família Llama, de pesos abertos

Fonte: elaborado pelo autor (2026).

3 Decisão sobre o título

O ponto 1 pede revisar a palavra “verificados”, e o retorno indica que a decisão será tomada em conjunto. Proponho a troca por “apurados”:

Plataforma para geração de cenários de teste em sistemas ERP assistida por modelos de linguagem, com valores esperados apurados em banco de dados.

A troca deixa o título prometer exatamente o que a plataforma garante, um valor obtido do banco, rastreável e reprodutível, e transfere a questão da validação para onde ela é de fato respondida: a avaliação, por meio da acurácia e da taxa de falso acordo. A alternativa é manter “verificados” e defini-lo no texto como “obtido por execução e conferido por analista”. A primeira opção me parece mais honesta e evita que a banca volte ao ponto. A decisão será tomada na próxima orientação.

4 Como os ajustes chegam à versão final

A proposta já foi entregue e não será reescrita. Os ajustes são incorporados diretamente nas entregas parciais, que formam as seções do artigo do TCC I, e o Quadro 1 deste documento entra como apêndice da versão final, com o título *Ajustes solicitados na avaliação da proposta*. Na defesa de validação, o mesmo quadro é apresentado em um slide, acompanhado das evidências indicadas pela orientação:

- a distinção entre valor apurado e valor validado, e como a taxa de falso acordo mede a diferença;
- o inventário do que é enviado aos provedores em cada etapa e as medidas de minimização;
- os critérios de seleção escritos e os números do funil: 2.913 tarefas finalizadas no período, 694 disponíveis após os critérios verificáveis por consulta, e as selecionadas;
- a rubrica de aceitação com exemplos e a concordância entre os analistas;
- o desenho da comparação de tempo e o teste estatístico escolhido;

– a seção de limitações;
– o diagrama de contexto da plataforma em relação ao ERP.

O número de tarefas citado na proposta, mais de quinhentas, era uma estimativa. A versão final adota a contagem real do Apêndice E da E5.